

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-16607-111464

**Výber a návrh metód predspracovania
fotografií oblohy typu „fisheye“ pre odhad
solárneho žiarenia**

Diplomová práca

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-16607-111464

**Výber a návrh metód predspracovania
fotografií oblohy typu „fisheye“ pre odhad
solárneho žiarenia**

Diplomová práca

Študijný program: aplikovaná informatika
Študijný odbor: informatika
Školiace pracovisko: Ústav informatiky a matematiky
Vedúci záverečnej práce: Ing. Marián Šebeňa



ZADANIE DIPLOMOVEJ PRÁCE

Autor práce: Bc. Róbert Šumšala
Študijný program: aplikovaná informatika
Študijný odbor: informatika
Evidenčné číslo: FEI-16607-111464
ID študenta: 111464
Vedúci práce: Ing. Marián Šebeňa
Vedúci pracoviska: doc. Ing. Milan Vojvoda, PhD.
Miesto vypracovania: Ústav informatiky a matematiky

Názov práce: **Výber a návrh metód predspracovania fotografií oblohy typu „rybie oko“ pre odhad solárneho žiarenia**

Jazyk, v ktorom sa práca vypracuje: slovenský jazyk

Špecifikácia zadania: Cieľom diplomovej práce je analyzovať, navrhnúť a experimentálne vyhodnotiť metódy predspracovania celooblohových fotografií typu „fisheye“ v kontexte odhadu solárneho žiarenia. Práca sa zameria na návrh vlastného optimalizovaného referenčného modelu pre odhad žiarenia a systematické porovnanie rôznych scenárov predspracovania s cieľom určiť ich vplyv na presnosť výsledného modelu. Výstupom bude odporúčanie najvhodnejšej kombinácie metód predspracovania a identifikácia limitov a možností ďalšieho zlepšenia navrhnutého riešenia.

1. Analyzujte súčasný stav problematiky predspracovania celooblohových (fisheye) fotografií v kontexte odhadu solárneho žiarenia na základe odbornej literatúry.
2. Vyberte vhodný dataset obsahujúci celooblohové fisheye snímky a zodpovedajúce merania solárneho žiarenia.
3. Navrhnite a implementujte optimalizovaný referenčný model pre odhad žiarenia.
4. Navrhnite a implementujte scenáre predspracovania pre fisheye snímky na referenčnom modeli.
5. Experimentálne otestujte jednotlivé varianty predspracovania a vyhodnoťte ich vplyv na presnosť.
6. Vyvodte závery a odporučte najvhodnejšiu kombináciu metód predspracovania.

Rozsah práce: minimálne 2 AH a maximálne 3 AH okrem prípadnej ďalšej technickej dokumentácie

Literatúra:

1. GOODFELLOW IAN; BENGIO, Yoshua; COURVILLE, Aaron. *Deep Learning*. Cambridge : Massachusetts Institute of Technology, 2016. 775 s. ISBN 978-0-262-03561-3.
2. ŠEBEŇA, Marián a KAČUR, Juraj. Prediction of Solar Energy from Sky Images and Meteorological Data Using Neural Networks. In: Mario, MUŠTRA; Josip, VUKOVIĆ a Jelena, BOŽEK. *Proceedings ELMAR-2023*. Zadar: Croatian Society Electronics in Marine, 2023, s. 189–192. ISBN 979-8-3503-2511-9.

Termín odovzdania práce: 15. 05. 2026

Dátum schválenia zadania práce: **27. 03. 2026**

Zadanie práce schválil: **prof. Dr. rer. nat. Martin Drozda**
garant študijného programu

Vyhlásenie autora

Podpísaný Bc. Róbert Šumšala čestne vyhlasujem, že som diplomovú prácu „*Výber a návrh metód predspracovania fotografií oblohy typu „fisheye“ pre odhad solárneho žiarenia*“ vypracoval samostatne na základe poznatkov získaných počas štúdia a s využitím odbornej literatúry uvedenej v zozname použitej literatúry.

Uvedenú prácu som vypracoval pod vedením Ing. Mariána Šebeňu.

V Bratislave dňa 15. 05. 2026



.....
podpis autora

Pod'akovanie

Týmto by som sa chcel poďakovať Ing. Mariánovi Šebeňovi, vedúcemu diplomovej práce, za odborné vedenie, cenné konzultácie a výbornú komunikáciu počas vypracovávania tejto práce. Jeho pripomienky a odporúčania významne prispeli ku kvalite výsledného riešenia práce.

Abstrakt

Cieľom tejto práce je návrh a implementácia modelu pre predikciu globálneho slnečného žiarenia na základe celooblohových snímok. Implementácia riešenia bola realizovaná v programovacom jazyku Python. V rámci riešenia bol použitý dataset SkyCam a analyzovaný vplyv rôznych techník predspracovania obrazových dát, farebných priestorov a nastavení konvolučnej neurónovej siete na presnosť predikcie. Súčasťou práce bola aj optimalizácia hyperparametrov modelu pomocou frameworku Optuna a následné vyhodnotenie modelu prostredníctvom 10-násobnej krížovej validácie.

Výsledky experimentov ukázali, že najväčší prínos pre presnosť modelu mala zmena farebného priestoru na HSV spolu s orezaním a maskovaním snímok. Naopak, dátové augmentácie ani techniky odstraňovania fisheye skreslenia nepriniesli výrazné zlepšenie výsledkov, a preto neboli použité vo finálnej konfigurácii modelu. Finálny model dosiahol pri testovaní hodnotu RMSE $12.0522 \pm 2.6358 \text{ W/m}^2$ a MAE $7.3295 \pm 1.6081 \text{ W/m}^2$, pričom preukázal stabilné výsledky a dobrú schopnosť generalizácie na neznámych dátach.

Kľúčové slová

Slnečné žiarenie, konvolučné neurónové siete, predikcia slnečného žiarenia, spracovanie obrazových dát

Abstract

The aim of this thesis is to design and implement a model for predicting global solar irradiance based on all-sky images. The implementation was developed in the Python programming language. The SkyCam dataset was used, and the influence of various image preprocessing techniques, color spaces, and convolutional neural network configurations on prediction accuracy was analyzed. The thesis also included hyperparameter optimization using the Optuna framework and subsequent evaluation of the model through 10-fold cross-validation.

The experimental results showed that the most significant improvement in model accuracy was achieved by converting the input images to the HSV color space together with image cropping and masking. In contrast, data augmentation techniques and fisheye distortion removal did not provide significant improvements and were therefore not included in the final model configuration. The final model achieved a test RMSE of 12.0522 ± 2.6358 W/m² and a test MAE of 7.3295 ± 1.6081 W/m², while demonstrating stable performance and good generalization capability on unseen data.

Keywords

Solar irradiance, convolutional neural network, solar irradiance prediction, image data processing

Obsah

Zoznam obrázkov	11
Zoznam tabuliek	13
Zoznam značiek a skratiek	15
Úvod	16
1 Slnčné žiarenie a jeho význam	18
1.1 Charakteristika slnečného žiarenia	18
1.2 Zložky slnečného žiarenia	18
1.3 Význam a využitie v energetike	18
1.4 Meranie slnečného žiarenia	20
2 Celooblohové zobrazovacie systémy	21
2.1 Fisheye kamery	21
2.2 Geometrické skreslenie a charakteristiky obrazu	21
3 Metodológia skúmanej problematiky	23
3.1 Predspracovanie obrazových dát	23
3.1.1 Základný postup predspracovania	23
3.1.2 Zmena veľkosti obrazu	23
3.1.3 Transformácia farebného obrazu	23
3.1.4 Normalizácia dát	26
3.1.5 Výber kanálu	26
3.1.6 Dátové augmentácie	26
3.1.7 Geometrické augmentácie	26
3.1.8 Farebné augmentácie	27
3.1.9 Priestorové augmentácie	28
3.2 Predikcia slnečného žiarenia	30
3.2.1 Model perzistencie	30
3.2.2 Fyzikálne a satelitné modely	30
3.2.3 Modely založené na celooblohových snímkach	31
3.3 Extrakcia príznakov	31
3.3.2 Porovnanie hlbokého učenia a tradičných prístupov v kontexte extrakcie príznakov pri predikcii slnečného žiarenia	32
3.4 Konvolučné neurónové siete (CNN)	32
3.4.1 Konvolučná vrstva	33
3.4.2 Pooling vrstva	33
3.4.3 Plne prepojená vrstva	34
3.4.4 Aktivačná funkcia	34
3.4.5 Stratová funkcia	34
3.4.6 Optimalizačné algoritmy	34
3.4.7 Vhodnosť CNN pre analýzu snímok oblohy	35
3.5 Hodnotiace metriky	35
3.5.1 Stredná absolútna chyba (MAE)	36
3.5.2 Koreň strednej kvadratickej chyby (RMSE)	36

3.5.3 Koeficient determinácie (R^2)	36
3.6 Křížová validácia typu k-fold	37
3.7 Optimalizácia hyperparametrov pomocou frameworku Optuna	37
3.7.1 Optuna framework	38
3.7.2 Optimalizované hyperparametre v tejto práci	38
4 Analýza súčasného stavu problematiky	40
4.1 Prístup založený na transfer learningu a časových sekvenciách	40
4.2 Predikcia vývoja oblohy a odstránenie fisheye deformácie snímok	40
4.3 Kombinácia extrakcie príznakov a klasických metód	41
4.4 Predikcia slnečného žiarenia pomocou CNN a LSTM sietí	41
4.5 Zhrnutie a porovnanie analyzovaných riešení	42
5 Výber datasetu	43
5.1 SkyCam dataset	43
5.2 Úprava datasetu SkyCam pre potreby nášho modelu	45
6 Návrh a implementácia referenčného modelu pre odhad slnečného žiarenia	46
6.1 Návrh vlastnej konvolučnej neurónovej siete	46
6.1.1 Vstup a predspracovanie dát	46
6.1.2 Generovanie dát a spracovanie dávok	46
6.1.3 Konvolučná časť siete	47
6.1.4 Normalizačné a aktivačné mechanizmy	47
6.1.5 Husto prepojená časť siete	47
6.1.6 Tréning modelu	48
6.2 Manuálna predbežná optimalizácia hyperparametrov	48
6.2.1 Popis experimentu	48
6.2.2 Výsledky experimentu	48
6.2.3 Záver experimentu	50
6.3 Optimalizácia hyperparametrov pomocou Optuna	51
6.3.1 Popis experimentu	51
6.3.2 Optimalizácia pamäťovej náročnosti	51
6.3.3 Definícia priestoru hyperparametrov	54
6.3.4 Priebeh experimentu	54
6.3.5 Výsledky experimentu	55
6.3.6 Záver experimentu	56
7 Návrh scenárov predspracovania fisheye snímok	58
7.1 Analýza vplyvu farebného priestoru a jednotlivých kanálov	58
7.1.1 Popis experimentu	58
7.1.2 Zdôvodnenie nezahrnutia farebného priestoru CMYK	59
7.1.3 Metodika experimentu	59
7.1.4 Výsledky experimentu	59
7.1.5 Záver experimentu	63
7.2 Orezanie a maskovanie snímok	64
7.2.1 Popis experimentu	64
7.2.2 Metodika experimentu	64

7.2.3 Výsledky experimentu	65
7.2.4 Záver experimentu	66
7.3 Úpravy geometrického skreslenia spôsobeného fisheye kamerou	66
7.3.1 Popis experimentu	66
7.3.2 Metodika experimentu	67
7.3.3 OpenCV lineárna projekcia	67
7.3.4 Rozdelenie obrazu na rovnaké uhlové sektory	68
7.3.5 Výsledky experimentu	69
7.3.6 Záver experimentu	69
8 Experimentálne testovanie augmentácií	71
8.1 Popis experimentu	71
8.2 Vyradené augmentácie	71
8.3 Metodika experimentu	71
8.4 Vizuálne ukážky augmentácií	73
8.5 Výsledky experimentu	74
8.6 Záver experimentu	75
9 Finálna evaluácia modelu	76
9.1 Výsledky finálnej evaluácie	76
10 Diskusia výsledkov	78
10.1 Porovnanie finálneho a referenčného modelu	78
10.2 Vyhodnotenie metód predspracovania snímok	78
Záver	79
Literatúra	80
Použitie nástrojov umelej inteligencie	83
Dodatok A: Pokyny na spustenie a používanie zdrojového kódu	84
Prílohy	85
Príloha 1: Schéma finálneho modelu	86
Príloha 2: Obsah elektronickej prílohy	87

Zoznam obrázkov

Obr. 1: Nárast kapacity fotovoltických systémov v GW [3]	19
Obr. 2: Nárast kapacity obnoviteľných zdrojov energie v GW [3]	19
Obr. 3: Geometrické skreslenie obrazu fisheye kamerou [5]	22
Obr. 4: Vizualizácia RGB farebného priestoru [8]	24
Obr. 5: Vizualizácia HSV farebného priestoru [8]	24
Obr. 6: Vzorový obrázok a jeho Y (vpravo hore), Cb (vľavo dole) a Cr (vpravo dole) zložky [9]	25
Obr. 7: Vizualizácia CMYK farebného priestoru [8]	25
Obr. 8: Príklad obrázka po aplikovaní augmentácie CLAHE [12]	28
Obr. 9: Príklad obrázka po aplikovaní augmentácie, ktorá pridá do originálu šum [13]	28
Obr. 10: Príklad obrázka po aplikovaní CutMix augmentácie [14]	29
Obr. 11: Príklad obrázka po aplikovaní augmentácie typu oklúzia [14]	29
Obr. 12: Princíp fungovania konvolučnej vrstvy	33
Obr. 13: Zjednodušený diagram konvolučnej neurónovej siete	35
Obr. 14: Diagram popisujúci princíp 5k-fold validácie	37
Obr. 15: Príklad sekvencie 13 snímok s narastajúcou expozíciou. Posledný obrázok predstavuje finálnu HDR snímku, ktorá vznikla kombináciou predchádzajúcich snímok. [29]	44
Obr. 16: Pyranometer (vľavo) a kamera (vpravo) použitá pri vytváraní SkyCam datasetu [29]	44
Obr. 17: Graf popisujúci priebeh učenia CNN s najlepším nastavením hyperparametrov podľa výsledkov z manuálnej optimalizácie hyperparametrov	50
Obr. 18: Graf popisujúci priebeh učenia nanovo natrénovaného modelu s parametrami z 30 pokusov optimalizácie pomocou frameworku Optuna	56
Obr. 19: Graf popisujúci priebeh učenia nanovo natrénovaného modelu s parametrami z 45 pokusov optimalizácie pomocou frameworku Optuna	56
Obr. 20: Grafy reprezentujúce výsledky troch behov analýzy kanálov farebného priestoru RGB	61

Obr. 21: Grafy reprezentujúce výsledky troch behov analýzy kanálov farebného priestoru HSV	62
Obr. 22: Grafy reprezentujúce výsledky troch behov analýzy kanálov farebného priestoru YCrCb.....	62
Obr. 23: Grafy reprezentujúce výsledky troch behov analýzy celých farebných priestorov	63
Obr. 24: Vzorový snímok z datasetu zobrazený v HSV farebnom priestore	63
Obr. 25: Vzorový snímok z datasetu bez orezania a bez maskovania.....	64
Obr. 26: Príklad orezaného snímku (vľavo) a orezaného snímku s aplikovanou maskou – čierne oblasti nahradené priemernou farbou snímky(vpravo).....	65
Obr. 27: Porovnanie originálneho vstupného obrázku (vľavo) s obrázkom po aplikovaní OpenCV lineárnej projekcie (vpravo)	68
Obr. 28: Porovnanie originálneho vstupného obrázku (vľavo) s obrázkom po aplikovaní rozdelenia obrazu na rovnaké uhlové sektory (vpravo).....	69
Obr. 29: Príklady augmentácií: žiadna augmentácia (vľavo), rotácia (v strede), posun (vpravo)	73
Obr. 30: Príklady augmentácií: zmena mierky (vľavo), zmena jasú (v strede), CLAHE (vpravo)	73
Obr. 31: Príklady augmentácií: pridanie šumu (vľavo), rozmazanie (vpravo).....	74
Obr. 32: Krivka učenia finálneho modelu	77
Obr. 33: Graf rezíduí finálneho modelu	77

Zoznam tabuliek

Tabuľka 1: Výsledky manuálnej optimalizácie hyperparametrov	49
Tabuľka 2: Priradenie veľkosti dávky v závislosti od rozlíšenia vstupného obrazu z dôvodu optimalizácie pamäťovej náročnosti	52
Tabuľka 3: Podmienky a dôvody predčasného ukončenia pokusov Optuna z dôvodu optimalizácie pamäťovej náročnosti.....	53
Tabuľka 4: Definícia priestoru hyperparametrov pre optimalizáciu modelu pomocou frameworku Optuna	54
Tabuľka 5: Výsledky nanovo natrénovaných modelov s hyperparametrami z 30 a 45 pokusov optimalizácie pomocou frameworku Optuna.....	55
Tabuľka 6: Optimálne nastavenie hyperparametrov podľa optimalizácie pomocou frameworku Optuna (použité v ďalších experimentoch).....	57
Tabuľka 7: Nastavenie modelu pre testovanie vplyvu farebných priestorov a jednotlivých farebných kanálov.....	59
Tabuľka 8: Priemerné výsledky z troch behov pre jednotlivé kanály RGB farebného priestoru	60
Tabuľka 9: Priemerné výsledky z troch behov pre jednotlivé kanály HSV farebného priestoru	60
Tabuľka 10: Priemerné výsledky z troch behov pre jednotlivé kanály YCrCb farebného priestoru	60
Tabuľka 11: Priemerné výsledky z troch behov pre jednotlivé farebné priestory	60
Tabuľka 12: Nastavenie modelu pre testovanie vplyvu orezania a maskovania snímok ..	64
Tabuľka 13: Priemerné výsledky analýzy vplyvu orezávania a maskovania vstupných snímok	65
Tabuľka 14: Nastavenie modelu pre testovanie vplyvu úpravy geometrického skreslenia spôsobeného fisheye kamerou	67
Tabuľka 15: Priemerné výsledky analýzy vplyvu úpravy geometrického skreslenia spôsobeného fisheye kamerou	69
Tabuľka 16: Nastavenie modelu pre testovanie vplyvu augmentácií.....	72
Tabuľka 17: Priemerné výsledky analýzy jednotlivých augmentácií a štatistika počtu aplikácií	74

Tabuľka 18: Priemerný počet použitých augmentácií pri tréovaní s kombináciou augmentácií.....	75
Tabuľka 19: Priemerné výsledky kombinácií najvhodnejších augmentácií	75
Tabuľka 20: Nastavenie modelu pre finálnu evaluáciu	76
Tabuľka 21: Výsledky 10-násobnej krížovej validácie finálneho modelu	76
Tabuľka 22: Porovnanie finálneho a referenčného modelu.....	78

Zoznam značiek a skratiek

GHI – globálne horizontálne žiarenie z angl. *Global Horizontal Irradiance*

DNI – priame normálové žiarenie z angl. *Direct Normal Irradiance*

DHI – difúzne horizontálne žiarenie z angl. *Diffuse Horizontal Irradiance*

RGB – farebný priestor: červená, zelená, modrá z angl. *Red, Green, Blue*

HSV – farebný priestor: odtieň, sýtosť, jase z angl. *Hue, Saturation, Value*

YCrCb – farebný priestor: jas, červená zložka, modrá zložka z angl. *Luma, Chroma Red, Chroma Blue*

CMYK – farebný priestor: azúrová, purpurová, žltá, čierna z angl. *Cyan, Magenta, Yellow, Key/Black*

SIFT – invariantná transformácia príznakov voči mierke z angl. *Scale-Invariant Feature Transform*

SURF – zrýchlené robustné príznaky z angl. *Speeded-Up Robust Features*

FAST – príznaky zrýchleného segmentového testu z angl. *Features from Accelerated Segment Test*

SVM – metóda podporných vektorov z angl. *Support Vector Machine*

KNN – k-najbližších susedov z angl. *K-Nearest Neighbors*

CNN – konvolučné neurónové siete z angl. *Convolutional Neural Network*

ReLU – rektifikovaná lineárna jednotka z angl. *Rectified Linear Unit*

MAE – stredná absolútna chyba z angl. *Mean Absolute Error*

RMSE – stredná kvadratická chyba z angl. *Root Mean Square Error*

MSE – stredná kvadratická chyba z angl. *Mean Square Error*

R^2 – koeficient determinácie

SGD – stochastický gradientný zostup z angl. *Stochastic Gradient Descent*

TSI – označenie datasetu: celoblokový zobrazovač z angl. *Total Sky Imager*

PSNR – špičkový pomer signálu k šumu z angl. *Peak Signal-to-Noise Ratio*

LSTM – sieť s dlhou krátkodobou pamäťou z angl. *Long Short-Term Memory*

HDR – vysoko dynamický obsah z angl. *High Dynamic Range*

OOM – označenie chyby spôsobenej nedostatkom pamäte z angl. *Out Of Memory*

Úvod

Slnčné žiarenie predstavuje jeden z najvýznamnejších obnoviteľných zdrojov energie, ktorého význam v posledných rokoch dynamicky rastie. S postupujúcou transformáciou energetiky smerom k udržateľným riešeniam sa čoraz väčší dôraz kladie nielen na samotnú výrobu elektrickej energie z fotovoltických systémov, ale aj na jej efektívne riadenie a predikciu. Práve schopnosť presne odhadnúť dostupné množstvo solárneho žiarenia v reálnom čase či krátkodobom horizonte predstavuje kľúčový faktor pre stabilitu a optimalizáciu energetických systémov.

Ako uvádza [1], *„Podiel výroby elektrickej energie z fotovoltických systémov na celkovej dodávke elektriny neustále rastie. Efektívne využívanie kolísajúcej produkcie solárnej energie si vyžaduje spoľahlivé predikcie očakávanej výroby. Tieto predikcie zohrávajú kľúčovú úlohu pri riadení elektrických sietí, ako aj pri obchodovaní so solárnou energiou.“* Táto skutočnosť poukazuje na potrebu vývoja presných a robustných metód pre odhad solárneho žiarenia.

Jedným z perspektívnych prístupov k riešeniu tejto úlohy je využitie celooblohových fotografií, často snímaných pomocou kamier s tzv. „fisheye“ objektívom. Tieto snímky poskytujú komplexný pohľad na oblohu vrátane oblačnosti, ktorá má zásadný vplyv na intenzitu dopadajúceho žiarenia. Na prvý pohľad ide o bohatý zdroj informácií, ktorý však prináša aj množstvo výziev. Od geometrického skreslenia cez variabilitu osvetlenia až po prítomnosť rušivých objektov. Otázkou preto nie je len to, ako tieto dáta využiť, ale predovšetkým ako ich vhodne spracovať.

V súčasnosti sa pri spracovaní obrazových dát čoraz častejšie uplatňujú metódy strojového učenia, najmä konvolučné neurónové siete. Ich schopnosť extrahovať relevantné príznaky priamo z obrazových vstupov z nich robí vhodného kandidáta pre úlohy spojené s analýzou oblohy a odhadom solárneho žiarenia. Napriek tomu však samotný model nie je jediným rozhodujúcim faktorom úspechu. Kvalita vstupných dát a spôsob ich predspracovania môžu mať zásadný vplyv na výslednú presnosť modelu.

Táto diplomová práca sa preto zameriava na analýzu a návrh metód predspracovania celooblohových fotografií typu „fisheye“ v kontexte odhadu solárneho žiarenia. Cieľom je navrhnúť referenčný model založený na konvolučných neurónových sieťach a systematicky preskúmať, ako rôzne prístupy k predspracovaniu ovplyvňujú jeho výkonnosť. Dôraz sa kladie najmä na identifikáciu takých kombinácií metód, ktoré vedú k najpresnejším výsledkom, ako aj na pochopenie ich obmedzení.

Implementačná časť tejto práce bola realizovaná v programovacom jazyku Python, ktorý bol zvolený vzhľadom na jeho širokú podporu v oblasti strojového učenia a spracovania obrazových dát. Využitie tohto jazyka umožnilo efektívnu implementáciu

navrhnutého modelu a realizáciu experimentov súvisiacich s jeho optimalizáciou a vyhodnotením.

Nasledujúce kapitoly práce postupne predstavujú teoretické východiská riešenej problematiky, prehľad súčasného stavu poznania, návrh a implementáciu modelu, ako aj experimentálne vyhodnotenie jednotlivých prístupov. Výsledkom je komplexný pohľad na význam predspracovania obrazových dát pri odhade solárneho žiarenia a odporúčania pre jeho efektívne využitie v praxi.

1 Slnčné žiarenie a jeho význam

1.1 Charakteristika slnečného žiarenia

Slnčné žiarenie predstavuje elektromagnetické žiarenie emitované Slnkom, ktoré vzniká v dôsledku termonukleárných reakcií v jeho jadre. Toto žiarenie sa šíri priestorom vo forme elektromagnetických vĺn rôznych vlnových dĺžok, pričom najvýznamnejšiu časť z hľadiska energetických aplikácií tvorí viditeľná a blízka infračervená oblasť spektra.

Slnčné žiarenie predstavuje základný zdroj energie pre väčšinu procesov prebiehajúcich na Zemi a zároveň tvorí kľúčový vstup pre systémy využívajúce obnoviteľné zdroje energie. V kontexte energetiky ide o fyzikálnu veličinu vyjadrujúcu množstvo energie dopadajúcej na jednotku plochy za jednotku času, pričom sa najčastejšie udáva vo wattoch na meter štvorcový (W/m^2). Presné pochopenie charakteru a variability slnečného žiarenia je nevyhnutné nielen pre návrh a optimalizáciu fotovoltických systémov, ale aj pre ich efektívne riadenie a integráciu do elektrizačných sústav [2].


1.2 Zložky slnečného žiarenia

Z hľadiska fyzikálnej interpretácie sa slnečné žiarenie rozdeľuje na niekoľko základných zložiek. Globálne horizontálne žiarenie (GHI – Global Horizontal Irradiance) predstavuje celkové množstvo žiarenia dopadajúceho na horizontálnu plochu a zahŕňa priamu aj difúznú zložku. Priame normálové žiarenie (DNI – Direct Normal Irradiance) označuje zložku žiarenia prichádzajúcu priamo zo slnka bez rozptylu v atmosfére, pričom sa meria na ploche kolmej na smer dopadu slnečných lúčov. Difúzne horizontálne žiarenie (DHI – Diffuse Horizontal Irradiance) predstavuje žiarenie rozptýlené v atmosfére, ktoré dopadá na povrch zo všetkých smerov oblohy. Tieto tri veličiny spolu poskytujú komplexný opis radiačných podmienok a ich vzájomný pomer je významne ovplyvnený aktuálnym stavom atmosféry, najmä oblačnosťou, aerosólmi a ďalšími meteorologickými faktormi [2].


1.3 Význam a využitie v energetike

Význam slnečného žiarenia v súčasnosti úzko súvisí s dynamickým rozvojom fotovoltických technológií a rastúcim podielom obnoviteľných zdrojov energie na celkovej výrobe elektriny. Dostupnosť rôznych foriem obnoviteľných zdrojov energie v kombinácii s technologickým pokrokom v oblasti ich využívania predstavuje atraktívnu príležitosť pre energetických producentov na celom svete. Masová výroba komponentov pre obnoviteľné zdroje zároveň výrazne znížila jednotkové náklady, čo prispieva

k rýchlejšiemu rozširovaniu týchto technológií. Významným faktorom sú aj vládne politiky a strategické plány, ktoré podporujú investície do zelenej energie. Príkladom je India, ktorá sa zaviazala k tzv. Mission 500 GW plan, stanovujúcemu cieľ dosiahnuť kapacitu 500 gigawattov z obnoviteľných zdrojov do roku 2030. Z hľadiska podielu na výrobe majú kľúčovú pozíciu solárne a veterné elektrárne, pričom solárna fotovoltická energia je preferovaná najmä pre jednoduchú prepravu, údržbu a širokú dostupnosť zdrojov. Rastúca kapacita fotovoltických systémov a obnoviteľných zdrojov energie v gigawattoch je znázornená na obr. č. 1 a obr. č. 2 [3].



Obr. 1: Nárast kapacity fotovoltických systémov v GW [3]



Obr. 2: Nárast kapacity obnoviteľných zdrojov energie v GW [3]

V dôsledku dynamického rozvoja obnoviteľných zdrojov energie rastie aj význam predikcie meteorologických veličín, ako sú rýchlosť vetra či intenzita solárneho žiarenia. Predikčné systémy pre veternú energiu už preukázali výrazný ekonomický prínos a prispeli k lepšej integrácii veternej energie do elektrickej siete. Podobný trend možno očakávať aj pri solárnej energii, ktorej podiel v energetickom mixe neustále narastá. Pre distribučné spoločnosti sa preto stáva čoraz dôležitejšou schopnosť predpovedať výrobu z fotovoltických systémov, a to najmä v krajinách, kde legislatíva podporuje nasadzovanie solárnych elektrární. Ako príklad možno uviesť Španielsko, kde systém podpory výroby zahŕňa aj motivačné mechanizmy pre poskytovanie denných predikcií solárneho výkonu. V Nemecku inštalovaný výkon fotovoltických elektrární presahuje už niekoľko gigawattov a v Bavorsku, kde sa nachádza veľká časť týchto systémov, môže podiel solárnej energie dodávanej do siete počas slnečných dní dosiahnuť až 10 % v čase špičky. Spoločlivé predikcie solárneho žiarenia a následne aj výroby elektrickej energie preto predstavujú

kľúčový predpoklad pre stabilitu elektrizačných sústav, efektívnu prevádzku a obchodovanie s elektrinou z obnoviteľných zdrojov [1].

1.4 Meranie slnečného žiarenia

Nasledujúci prehľad spôsobov merania slnečného žiarenia a jeho významu vychádza z [4]. Okrem samotného významu žiarenia je nevyhnutné venovať pozornosť aj spôsobom jeho merania. Na získavanie presných údajov o intenzite slnečného žiarenia sa využívajú špecializované meteorologické prístroje:

- pyranometer
- pyrhelimeter

Pyranometer slúži na meranie globálneho horizontálneho žiarenia, pričom zaznamenáva celkový tok energie dopadajúci na horizontálnu plochu.

Pyrhelimeter sa používa na meranie priameho normálového žiarenia a vyžaduje presné sledovanie polohy slnka. Difúzne žiarenie sa zvyčajne získava nepriamo, napríklad tienením priamej zložky pomocou špeciálnych tieniacich zariadení.

Okrem tradičných meracích prístupov sa v posledných rokoch čoraz viac uplatňujú aj alternatívne metódy založené na analýze obrazových dát, najmä celooblohových snímok, ktoré umožňujú zachytiť aktuálny stav oblačnosti a jeho dynamiku.

Presné meranie a následná predikcia slnečného žiarenia tak predstavujú neoddeliteľnú súčasť moderných energetických systémov. Vzhľadom na vysokú variabilitu atmosférických podmienok a komplexnosť procesov ovplyvňujúcich šírenie žiarenia je však táto úloha mimoriadne náročná. Práve preto sa v súčasnosti kladie dôraz na vývoj pokročilých metód, ktoré dokážu efektívne využiť dostupné dáta a poskytovať spoľahlivé odhady.

2 Celooblohové zobrazovacie systémy

Celooblohové zobrazovacie systémy predstavujú špecializované zariadenia určené na zachytávanie celej hemisféry oblohy v jednom obrazovom zábere. Ich hlavnou úlohou je poskytovať komplexný vizuálny prehľad o aktuálnom stave atmosféry, najmä o rozložení a pohybe oblačnosti. Tieto systémy sa využívajú v meteorológii, klimatológii, ako aj v aplikáciách spojených s obnoviteľnými zdrojmi energie, kde je dôležitá informácia o okamžitých podmienkach slnečného žiarenia. V porovnaní s tradičnými meracími prístrojmi poskytujú obrazové systémy dodatočný rozmer informácií [5]:

- priestorové rozloženie oblačnosti
- tvar oblakov
- počet oblakov
- hustota oblačnosti
- pohyb a dynamika oblakov v čase


Informácie, ktoré sú vhodné pri využití metód počítačového videnia a strojového učenia [6].

2.1 Fisheye kamery

Jedným z najčastejšie používaných riešení pre celooblohové snímanie sú kamery vybavené tzv. „fisheye“ objektívom. Tento typ objektívu je navrhnutý tak, aby zachytil extrémne široké zorné pole, typicky až 180 stupňov alebo viac, čo umožňuje zobrazenie celej oblohy v jednom snímku. Výsledný obraz však podlieha výraznému geometrickému skresleniu, ktoré je charakteristické nelineárnym mapovaním priestorových bodov na obrazovú rovinu. Toto skreslenie je nevyhnutnou daňou za široké zorné pole a musí byť zohľadnené pri následnom spracovaní dát [6].

2.2 Geometrické skreslenie a charakteristiky obrazu

Obrazy získané pomocou fisheye kamier vykazujú špecifické deformácie, pri ktorých sa objekty nachádzajúce sa bližšie k okrajom snímky javia výrazne menšie. Naopak objekty priamo nad kamerou môžu byť väčšie a natiahnuté. Tento efekt je spôsobený projekčnou transformáciou, ktorá mapuje trojrozmernú scénu na dvojrozmerný obrazový priestor. Typický príklad tohto javu je znázornený na obr. č. 3, kde je jasne viditeľné radiálne skreslenie smerom od stredu obrazu [5].



Obr. 3: Geometrické skreslenie obrazu fisheye kamerou [5]

Z hľadiska spracovania obrazových dát je dôležité si uvedomiť, že uvedené charakteristiky môžu ovplyvniť extrakciu príznačkov a následnú presnosť modelov strojového učenia. Preto je nevyhnutné venovať pozornosť skúmaniu efektu týchto skreslení pre daný trénovaný model a dataset.

3 Metodológia skúmanej problematiky

3.1 Predspracovanie obrazových dát

3.1.1 Základný postup predspracovania

Na základe poznatkov uvedených v práci [7] bol v rámci tejto práce navrhnutý jednotný predspracovací postup pozostávajúci zo štyroch hlavných krokov:

- zmena veľkosti obrazu
- transformácia farebného priestoru
- normalizácia
- voliteľný výber kanála.

3.1.2 Zmena veľkosti obrazu

Prvým krokom je zjednotenie rozmerov vstupných snímok prostredníctvom operácie zmeny veľkosti. Tento krok zabezpečuje, že všetky vstupy do neurónovej siete majú identickú dimenziu, čo je nevyhnutné pre dávkové spracovanie a stabilné učenie modelu. Zmena veľkosti sa vykonáva bez predchádzajúcej normalizácie.

3.1.3 Transformácia farebného obrazu


V závislosti od konfigurácie môže byť obraz ponechaný v RGB priestore alebo prevedený do alternatívnych reprezentácií. Cieľom tohto kroku je umožniť modelu pracovať s rôznymi formami farebnej informácie, ktoré môžu lepšie zachytávať štruktúru oblohy a oblačnosti.

Farebné priestory predstavujú rôzne spôsoby reprezentácie farebných informácií v digitálnom obraze, pričom každý z nich zdôrazňuje odlišné aspekty vizuálnych dát [8]. V tejto práci sa venujeme týmto farebným priestorom:

- RGB
- HSV
- YCrCb
- CMYK

RGB farebný priestor


Najčastejšie používaným modelom v oblasti počítačového videnia je RGB (Red, Green, Blue), ktorý reprezentuje obraz pomocou kombinácie troch základných farebných zložiek. Tento model je prirodzený pre zobrazovacie zariadenia, avšak nie vždy je optimálny pre analýzu obrazu, keďže neoddeľuje jasovú a farebnú informáciu. Prienik všetkých farieb tvorí bielu [8].



Obr. 4: Vizualizácia RGB farebného priestoru [8]

HSV farebný priestor


Alternatívou je HSV (Hue, Saturation, Value), ktorý rozdeľuje farebnú informáciu na odtieň, sýtosť a jas, čím lepšie korešponduje s ľudským vnímaním farieb a umožňuje jednoduchšie oddelenie intenzity osvetlenia od farebného tónu [8].



Obr. 5: Vizualizácia HSV farebného priestoru [8]

YCrCb farebný priestor


Ďalším často využívaným priestorom je YCrCb, ktorý separuje luminančnú zložku (Y) od chrominančných zložiek (Cr – červená, Cb – modrá), vďaka čomu je vhodný pre úlohy, kde je potrebné pracovať najmä s jasovou informáciou nezávisle od farby [8].



Obr. 6: Vzorový obrázok a jeho Y (vpravo hore), Cb (vľavo dole) a Cr (vpravo dole) zložky [9]

CMYK farebný priestor

V niektorých aplikáciách sa využíva aj CMYK (Cyan, Magenta, Yellow, Key/Black), ktorý je primárne určený pre tlačové technológie a vychádza z subtraktívneho miešania farieb. Prienik všetkých farieb tvorí čiernu [8].



Obr. 7: Vizualizácia CMYK farebného priestoru [8]

3.1.4 Normalizácia dát

Po transformácii farebného priestoru sa obraz konvertuje na dátový typ s desatinnou presnosťou (float32), ktorý umožňuje reprezentovať hodnoty pixelov ako reálne čísla. Použitie typu float32 predstavuje kompromis medzi presnosťou a pamäťovou náročnosťou, pričom je v praxi štandardom pri tréovaní neurónových sietí.

Následne sa vykoná normalizácia do rozsahu $\langle 0,1 \rangle$, a to škálovaním hodnôt pixelov delením konštantou 255, keďže pôvodné hodnoty sú v rozsahu $\langle 0,255 \rangle$. Týmto krokom sa zabezpečí jednotný rozsah vstupných dát, čo prispieva k stabilnejšiemu a rýchlejšiemu učeniu neurónovej siete. Zároveň sa znižuje riziko numerických problémov a zlepšuje sa správanie gradientov počas optimalizácie [10].

3.1.5 Výber kanálu

Posledným voliteľným krokom je extrakcia konkrétneho farebného kanála. Tento prístup umožňuje experimentovať s redukovanou reprezentáciou vstupu, napríklad využitím iba luminančnej zložky alebo iného vybraného kanála, čo môže zjednodušiť vstupný priestor modelu.

3.1.6 Dátové augmentácie

Nasledujúci prehľad dátových augmentácií a ich rozdelenia vychádza z poznatkov uvedených v práci [11]. Dátové augmentácie predstavujú techniku rozširovania tréningovej množiny pomocou syntetických transformácií existujúcich dát. Ich cieľom je zvýšiť robustnosť modelu voči variabilite vstupov a zlepšiť jeho generalizačnú schopnosť. Augmentácie možno rozdeliť do troch hlavných kategórií:

- **geometrické:** rotácia, posun, zmena mierky, shearing
- **farebné:** zmena jasu, zmena kontrastu, CLAHE
- **priestorové transformácie:** zrkadlenie, rozmazanie, šum, CutMix, oklúzia

3.1.7 Geometrické augmentácie

Geometrické transformácie modifikujú tvar alebo orientáciu obrazu bez zásadnej zmeny jeho obsahovej informácie.

Rotácia

Rotácia predstavuje otočenie obrazu o definovaný uhol. Umožňuje modelu naučiť sa invarianciu voči orientácii scény.

Posun (translation)

Posun obrazu simuluje zmenu polohy objektov v rámci snímky. Pomáha modelu zvládať mierne posuny objektov v obraze.

Zmena mierky (scaling)

Zmena mierky upravuje veľkosť obrazu alebo jeho častí, priblíženie, resp. oddialenie, čím sa simuluje variabilná vzdialenosť objektov od kamery.

Shearing

Shearing transformuje obraz skosením geometrie, čím simuluje perspektívne deformácie.

3.1.8 Farebné augmentácie

Farebné transformácie modifikujú hodnoty pixelov bez zmeny geometrickej štruktúry obrazu.

Zmena jasu

Upravuje celkovú svetelnosť obrazu a simuluje rôzne svetelné podmienky.

Zmena kontrastu

Zmena kontrastu zvyšuje alebo znižuje rozdiel medzi svetlými a tmavými oblasťami.

CLAHE

Contrast Limited Adaptive Histogram Equalization (CLAHE) zlepšuje lokálny kontrast obrazu a umožňuje zvýraznenie detailov v oblastiach s nízkym kontrastom.



Obr. 8: Príklad obrázka po aplikovaní augmentácie CLAHE [12]

3.1.9 Priestorové augmentácie

Priestorové augmentácie modifikujú obsah obrazu odstránením alebo kombinovaním jeho častí.

Zrkadlenie (mirroring)


Horizontálne alebo vertikálne preklopenie obrazu, ktoré zvyšuje variabilitu dát.

Rozmazanie (blur)

Aplikuje priestorové rozmazanie, ktoré simuluje zníženú ostrosť obrazu.

Šum (noise)

Pridanie náhodného šumu simuluje senzorové chyby alebo nepriaznivé podmienky snímania.



Obr. 9: Príklad obrázka po aplikovaní augmentácie, ktorá pridá do originálu šum [13]

CutMix

CutMix kombinuje dve rôzne snímky tak, že časť jednej je vložená do druhej, pričom sa upravujú aj cieľové hodnoty.



Obr. 10: Príklad obrázka po aplikovaní CutMix augmentácie [14]

Oklúzia (occlusion)

Simuluje zakrytie časti obrazu, čím núti model učiť sa robustné reprezentácie aj pri neúplných vstupoch.



Obr. 11: Príklad obrázka po aplikovaní augmentácie typu oklúzia [14]

3.2 Predikcia slnečného žiarenia

Predikcia solárnej energie je spojená s vysokou mierou neistoty, čo predstavuje zásadnú výzvu pri zabezpečovaní spoľahlivej výroby elektrickej energie. Pre výber vhodného modelu je nevyhnutné využívať dostupné meteorologické údaje, testovať a porovnávať viaceré prístupy a dôkladne hodnotiť ich presnosť v konkrétnych podmienkach danej lokality. Neustály vývoj v oblasti spracovania dát prináša nové stratégie a prístupy, ktorých cieľom je znížiť mieru nepresnosti a zvýšiť spoľahlivosť predikcie. Tradičné štatistické metódy sú často založené na diferenciálnych výpočtoch a analytických modeloch, zatiaľ čo dostupnosť rozsiahlych databáz meteorologických meraní umožnila nasadenie metód umelej inteligencie, využívaných na výpočet a predikciu intenzity solárneho žiarenia [3].

3.2.1 Model perzistencie

Model perzistencie predstavuje najjednoduchší a zároveň základný prístup k predikcii solárneho žiarenia a výkonu fotovoltických systémov, pričom sa často používa ako referenčný model na porovnanie s pokročilejšími metódami. Jeho princíp spočíva v predpoklade, že budúce hodnoty žiarenia budú rovnaké alebo veľmi podobné tým, ktoré boli namerané v nedávnej minulosti. V praxi sa tento model často vyjadruje prostredníctvom tzv. clear-sky indexu, ktorý umožňuje korigovať namerané údaje vzhľadom na ideálne podmienky bez oblačnosti. Perzistenčný model dosahuje relatívne dobrú presnosť počas jasných dní, kedy je intenzita slnečného žiarenia stabilná. Naopak, jeho presnosť výrazne klesá pri rýchlych zmenách oblačnosti, ktoré spôsobujú krátkodobé výkyvy žiarenia. Napriek svojej jednoduchosti zostáva tento model dôležitý ako základná referencia, pretože poskytuje minimálny štandard, ktorý musia pokročilejšie predikčné prístupy prekonať [15].

3.2.2 Fyzikálne a satelitné modely

Ďalšiu skupinu tvoria fyzikálne a satelitné modely, ktoré využívajú informácie o stave atmosféry získané zo satelitných snímok. Fyzikálne modely predstavujú prístup, ktorý využíva satelitné snímky na predikciu oblačnosti s vysokým priestorovým rozlíšením. Základom týchto modelov je identifikácia polohy oblakov a následné vyhodnotenie ich vlastností, najmä pokrytia a optickej hrúbky, ktoré zásadne ovplyvňujú presnosť predikcie. Fyzikálne satelitné modely umožňujú predpovedať intenzitu slnečného žiarenia spravidla s časovým horizontom do šiestich hodín dopredu, čo ich robí vhodnými najmä pre krátkodobé predikcie. Ich nevýhodou však môže byť nižšia časová presnosť v prípade rýchlo sa meniacej oblačnosti alebo pri lokálnych meteorologických javoch, ktoré satelitné merania nedokážu detailne zachytiť [15].

3.2.3 Modely založené na celooblohových snímkach

Špecifickú kategóriu predstavujú modely založené na celooblohových snímkach. Modely založené na snímkach oblohy (Sky Image) sa odlišujú od numerických predikčných modelov a satelitných modelov a sú obzvlášť užitočné pre predikcie solárneho žiarenia s krátkym časovým horizontom, napríklad v rámci hodiny. Fyzikálne prístupy využívajúce snímky oblohy zahŕňajú sledovanie pohybu oblakov, detekciu a klasifikáciu oblačnosti. Intenzita slnečného žiarenia dopadajúceho na povrch Zeme je veľmi citlivá na prítomnosť oblakov, zatiaľ čo iné zložky atmosféry, ako vodná para, aerosóly či vzduch, majú menší vplyv. Snímky oblohy poskytujú informácie o vlastnostiach oblakov, ako sú jas, veľkosť, tvar, spektrum a textúra, pričom textúra popisuje priestorové rozloženie pixelov v obraze.

Z pohľadu predikcie umožňujú samotné snímky vykonávať regionálne prognózy pre rôzne časové horizonty pomocou jednej kamery. Sky imager pozostáva hlavne z kamery a hemisférického zrkadla, pričom slnečný štít chráni kameru pred priamym slnečným žiarením. Na fotovoltickej elektrárni sú okrem kamery umiestnené aj senzory žiarenia, ktoré súčasne merajú intenzitu dopadajúceho žiarenia a zaznamenávajú snímky oblohy. Niektoré časti snímky môžu spôsobovať nežiaduci šum a znižovať presnosť predikcie, preto je potrebné tieto časti identifikovať a odstrániť pred spracovaním dát [16].

3.3 Extrakcia príznakov

Extrakcia príznakov predstavuje proces transformácie surových dát do kompaktnejšej a informatívnejšej reprezentácie, ktorá je vhodná pre ďalšie spracovanie alebo klasifikáciu. V kontexte obrazových dát ide o identifikáciu a výber charakteristických vlastností obrazu, ako sú hrany, textúry, tvary alebo farebné rozloženie, ktoré nesú relevantnú informáciu o jeho obsahu. Cieľom extrakcie príznakov je zjednodušiť vstupné dáta pri zachovaní ich najdôležitejších vlastností, čím sa znižuje výpočtová náročnosť a zároveň zvyšuje efektívnosť a presnosť modelov strojového učenia. V tradičných prístupoch sú príznaky definované manuálne, zatiaľ čo v hlbokom učení sú tieto príznaky učené automaticky priamo z dát [7].

Hlboké učenie (deep learning)

Hlboké učenie využíva viacvrstvové neurónové siete, ktoré umožňujú automatickú extrakciu príznakov priamo zo vstupných dát. V oblasti spracovania obrazov sa najčastejšie uplatňujú konvolučné neurónové siete [17].

Tradičné prístupy

Tradičné prístupy vychádzajú z explicitne definovaných algoritmov, ktoré extrahujú príznaky, ako sú hrany, textúry alebo farebné charakteristiky obrazu. Ich účinnosť je však závislá od kvality navrhnutých príznakov [17].

3.3.2 Porovnanie hlbokého učenia a tradičných prístupov v kontexte extrakcie príznakov pri predikcii slnečného žiarenia

Hlboké učenie (Deep Learning) výrazne posunulo hranice možností digitálneho spracovania obrazov a umožnilo automatickú extrakciu komplexných a abstraktných príznakov, ktoré boli tradičnými metódami ťažko dosiahnuteľné. Napriek tomu tradičné techniky počítačového videnia nezanikli a stále nachádzajú uplatnenie. Klasické metódy, ako extrakcia hrán, histogramy farieb alebo textúrne deskriptory, sú rýchle, interpretovateľné a vhodné pre menšie datasets. Naopak, ich nevýhodou je obmedzená schopnosť zachytiť komplexné vzory a kontextuálne informácie, ktoré hlboké neurónové siete zvládajú efektívne [17].

Tradičné metódy počítačového videnia využívajú explicitne definované príznaky, ako napríklad SIFT, SURF alebo FAST, ktoré sú následne spracované klasifikačnými algoritmami, napríklad SVM alebo KNN. Tieto prístupy sú výhodné najmä z hľadiska interpretovateľnosti a nižších výpočtových nárokov, avšak vyžadujú odborné znalosti pri návrhu príznakov a často nedokážu zachytiť komplexné vzory v dátach [18].

Na druhej strane, hlboké učenie umožňuje end-to-end prístup, pri ktorom model automaticky extrahuje príznaky priamo zo vstupných dát. Výhodou je vyššia presnosť, flexibilita a schopnosť pracovať s veľkým množstvom dát, pričom sa eliminuje potreba manuálnej extrakcie príznakov. Nevýhodou sú vyššie výpočtové nároky a nižšia interpretovateľnosť modelov. Medzi najvýznamnejšie prístupy hlbokého učenia v oblasti spracovania obrazov patria konvolučné neurónové siete (CNN), ktoré sú špeciálne navrhnuté na analýzu obrazových dát a umožňujú efektívnu extrakciu priestorových príznakov [19].

V súčasnosti sa čoraz častejšie uplatňujú hybridné prístupy, ktoré kombinujú výhody oboch paradigiem. Takéto riešenia umožňujú dosiahnuť vysokú presnosť pri súčasnom znížení výpočtovej náročnosti a lepšej interpretovateľnosti výsledkov [20].

3.4 Konvolučné neurónové siete (CNN)


Konvolučné neurónové siete (CNN) predstavujú špecializovanú triedu neurónových sietí navrhnutých na spracovanie obrazových dát. Ich základným stavebným prvkom je konvolučná vrstva, ktorá aplikuje filtre na vstupný obraz s cieľom extrahovať lokálne

príznyaky, ako sú hrany, textúry alebo tvary. Tieto príznaky sú následne kombinované vo vyšších vrstvách siete, čím vzniká hierarchická reprezentácia obrazu [21].

Okrem konvolučných vrstiev obsahuje CNN aj pooling vrstvy, husto prepojené vrstvy, stratovú funkciu a aktivačné funkcie, ktoré sa aplikujú na výstupy jednotlivých vrstiev. Každý z týchto prvkov plní špecifickú úlohu v procese spracovania dát a postupne transformuje vstupný obraz na výslednú reprezentáciu vhodnú pre predikciu. Výsledkom je schopnosť modelu učiť sa komplexné vzory priamo z dát bez potreby manuálneho návrhu príznakov [21].

3.4.1 Konvolučná vrstva

Konvolučná vrstva predstavuje základný stavebný prvok CNN. Jej úlohou je aplikovať sadu filtrov (jadier) na vstupný obraz, čím dochádza k extrakcii lokálnych príznakov, ako sú hrany, textúry alebo jednoduché tvary. Každý filter sa počas učenia prispôsobuje tak, aby detegoval špecifické vzory v dátach. Výstupom konvolučnej vrstvy je množina tzv. máp príznakov, ktoré reprezentujú prítomnosť rôznych príznakov v obraze [21].



Obr. 12: Princíp fungovania konvolučnej vrstvy

3.4.2 Pooling vrstva

Pooling vrstva slúži na zníženie priestorových rozmerov feature máp, čím sa redukuje výpočtová náročnosť modelu a zároveň sa zvyšuje jeho odolnosť voči malým posunom v obraze. Najčastejšie sa používa max pooling, ktorý z každej lokálnej oblasti vyberá maximálnu hodnotu, alebo average pooling, ktorý počíta priemer. Tento proces pomáha zachovať najdôležitejšie informácie pri súčasnom zjednodušení dát [21].

3.4.3 Plne prepojená vrstva

Plne prepojená vrstva, (z angl. *fully connected layer*) sa nachádza spravidla v závere CNN a slúži na finálne spracovanie extrahovaných príznakov. Každý neurón v tejto vrstve je prepojený so všetkými výstupmi z predchádzajúcej vrstvy, čo umožňuje kombinovať naučené príznaky do výslednej predikcie. V prípade regresných úloh, ako je odhad slnečného žiarenia, táto vrstva produkuje výslednú numerickú hodnotu [21].

3.4.4 Aktivačná funkcia


Aktivačná funkcia predstavuje nelineárnu transformáciu aplikovanú na výstup neurónu. Jej hlavnou úlohou je zaviesť nelinearitu do modelu, čo umožňuje neurónovej sieti učiť sa komplexné vzťahy medzi vstupmi a výstupmi. Bez aktivačných funkcií by bol model obmedzený na lineárne kombinácie vstupov a nedokázal by efektívne riešiť zložitejšie úlohy. Medzi najčastejšie používané aktivačné funkcie patria napríklad ReLU (Rectified Linear Unit), sigmoid alebo hyperbolický tangens [21].

3.4.5 Stratová funkcia

Stratová funkcia predstavuje matematický mechanizmus, ktorý vyjadruje mieru chyby medzi predikovanou hodnotou modelu a skutočnou hodnotou v tréningových dátach. Počas procesu učenia slúži ako hlavný ukazovateľ toho, ako presne model vykonáva svoju úlohu. Výber vhodnej stratovej funkcie závisí od typu riešeného problému, pričom pri regresných úlohách sa často využívajú metriky založené na rozdieloch medzi predikovanými a skutočnými hodnotami ako napríklad MSE, RMSE alebo MAE [21].

3.4.6 Optimalizačné algoritmy

Optimalizačné algoritmy slúžia na aktualizáciu váh neurónovej siete s cieľom minimalizovať hodnotu stratovej funkcie. Medzi najpoužívanejšie metódy patrí algoritmus Adam (Adaptive Moment Estimation), ktorý kombinuje výhody metód založených na momentoch gradientu a adaptívnom prispôbovaní rýchlosti učenia. Vďaka svojej efektívnosti a stabilite je Adam často preferovanou voľbou pri tréningu hlbokých neurónových sietí. Ďalším často používaným optimalizačným algoritmom je SGD, ktorý predstavuje jednoduchší prístup založený na postupnej aktualizácii váh podľa gradientu stratovej funkcie. [22].



Obr. 13: Zjednodušený diagram konvolučnej neurónovej siete

3.4.7 Vhodnosť CNN pre analýzu snímok oblohy

Použitie konvolučných neurónových sietí je obzvlášť vhodné pre analýzu celooblohových snímok, keďže tieto obrazy obsahujú komplexné priestorové vzory, ktoré sú ťažko popísateľné tradičnými metódami. CNN dokážu efektívne extrahovať príznaky spojené s oblačnosťou, jej štruktúrou, pohybom a jasovými charakteristikami, ktoré priamo ovplyvňujú intenzitu slnečného žiarenia.

Významnou výhodou je schopnosť pracovať s celým obrazom ako vstupom a automaticky identifikovať relevantné oblasti bez potreby explicitného definovania príznakov. Zároveň dokážu zachytiť nelineárne vzťahy medzi obrazovými dátami a cieľovou veličinou, čo je v prípade odhadu slnečného žiarenia kľúčové.

Napriek týmto výhodám je potrebné zohľadniť aj obmedzenia hlbokého učenia, najmä vysoké nároky na dáta a výpočtové zdroje, ako aj citlivosť na kvalitu vstupných dát. Práve preto zohráva predspracovanie obrazov zásadnú úlohu pri dosahovaní kvalitných výsledkov.

3.5 Hodnotiace metriky

Hodnotenie presnosti predikčných modelov predstavuje kľúčový krok pri analýze ich výkonnosti. V prípade regresných úloh, akou je aj odhad intenzity slnečného žiarenia, sa používajú metriky, ktoré kvantifikujú rozdiel medzi predikovanými a skutočnými hodnotami. Medzi najčastejšie používané patria stredná absolútna chyba (MAE), koreň strednej kvadratickej chyby (RMSE) a koeficient determinácie (R^2). Tieto metriky poskytujú rôzne pohľady na presnosť modelu a umožňujú jeho komplexné vyhodnotenie [23].

3.5.1 Stredná absolútna chyba (MAE)

Stredná absolútna chyba vyjadruje priemernú absolútnu odchýlku medzi predikovanými a skutočnými hodnotami. Ide o jednoduchú a intuitívnu metriku, ktorá poskytuje informáciu o priemernej veľkosti chyby bez ohľadu na jej smer.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

kde y_i predstavuje skutočnú hodnotu, $\hat{y}_i$ predikovanú hodnotu a n počet vzoriek. Výhodou MAE je jej interpretovateľnosť, nevýhodou je menšia citlivosť na veľké chyby [23].

3.5.2 Koreň strednej kvadratickej chyby (RMSE)

RMSE je podobná metrike MAE, avšak kladie väčší dôraz na väčšie chyby, keďže tieto sú kvadraticky penalizované.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

kde y_i predstavuje skutočnú hodnotu, $\hat{y}_i$ predikovanú hodnotu a n počet vzoriek. Táto vlastnosť robí RMSE vhodnou metriku v prípadoch, kde sú veľké odchýlky obzvlášť nežiadúce. Na druhej strane môže byť citlivá na extrémne hodnoty (outliers) [23].

3.5.3 Koeficient determinácie (R^2)


Koeficient determinácie vyjadruje, akú časť variability skutočných dát dokáže model vysvetliť. Jeho hodnota sa pohybuje typicky v intervale od 0 do 1, pričom vyššie hodnoty indikujú lepšiu zhodu modelu s dátami.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

kde $\bar{y}$ predstavuje priemernú hodnotu skutočných dát, y_i predstavuje skutočnú hodnotu, $\hat{y}_i$ predikovanú hodnotu a n počet vzoriek. Hodnota blízka 1 znamená vysokú presnosť modelu, zatiaľ čo hodnota blízka 0 naznačuje slabú predikčnú schopnosť [23].

3.6 Křížová validácia typu k-fold

Na doplnenie hodnotiacich metrík je potrebné zvoliť aj vhodnú metódu validácie modelu, ktorá zabezpečí objektívne posúdenie jeho výkonnosti. Křížová validácia typu k-fold predstavuje metódu hodnotenia modelu, ktorá umožňuje efektívne využiť dostupné dáta. Ako vidno na obr. č. 14, dataset sa rozdelí na k približne rovnako veľkých častí (tzv. foldov). Model sa následne trénuje k-krát, pričom v každej iterácii sa jedna časť použije ako validačná množina a zvyšné časti slúžia na tréning. Výsledná presnosť modelu sa získa spriemerovaním výsledkov zo všetkých iterácií. Tento prístup umožňuje spoľahlivejšie odhadnúť výkonnosť modelu a znižuje riziko skreslenia spôsobeného konkrétnym rozdelením dát. V rámci tejto práce bola k-fold validácia použitá výhradne na finálne vyhodnotenie navrhnutého modelu, keďže ide o výpočtovo náročnejší prístup, ktorý nie je vhodné aplikovať na všetky experimentálne konfigurácie. Jeho použitie na finálny model však umožnilo získať robustnejší odhad jeho generalizačnej schopnosti [24].



Obr. 14: Diagram popisujúci princíp 5k-fold validácie

3.7 Optimalizácia hyperparametrov pomocou frameworku Optuna

Na základe vyhodnotenia modelu pomocou metrík (MAE, RMSE, R²) a validačných postupov je ďalším krokom optimalizácia jeho hyperparametrov. Keďže výkon konvolučných neurónových sietí je výrazne závislý od nastavenia jednotlivých parametrov

architektúry a procesu učenia, v tejto práci bol na ich automatické vyhľadávanie použitý framework Optuna. Cieľom bolo nájsť kombináciu parametrov, ktorá minimalizuje chybu modelu a zároveň zlepšuje jeho generalizačnú schopnosť.

3.7.1 Optuna framework

Optuna predstavuje moderný framework pre automatickú optimalizáciu hyperparametrov v strojovom učení. Optuna funguje na princípe definovania objektívnej funkcie, ktorá:

1. navrhne konkrétnu kombináciu hyperparametrov
2. natrénuje model s danými parametrami
3. vyhodnotí jeho výkon
4. vráti hodnotu optimalizačnej metriky

Každé jedno spustenie objektívnej funkcie sa označuje ako pokus (z angl. *Trial*). Počas optimalizácie sa vykonáva viacero pokusov, pričom algoritmus sa postupne učí, ktoré oblasti priestoru hyperparametrov vedú k lepším výsledkom.

Framework využíva efektívne algoritmy pre vyhľadávanie optimálnych konfigurácií. Na základe výsledkov predchádzajúcich pokusov odhaduje pravdepodobnosť, že určitá kombinácia parametrov povedie k lepšiemu výsledku, a uprednostňuje perspektívnejšie oblasti priestoru. Zároveň podporuje tzv. prerezávanie (z angl. *Pruning*), teda predčasné ukončenie menej perspektívnych pokusov s cieľom znížiť výpočtovú náročnosť. Vďaka týmto vlastnostiam je Optuna vhodná najmä pre optimalizáciu hlbokých neurónových sietí.

V tejto práci bola použitá implementácia frameworku Optuna podľa štandardnej metodiky uvedenej v [25].

3.7.2 Optimalizované hyperparametre v tejto práci

V rámci experimentov boli pomocou Optuna optimalizované nasledujúce parametre:

- počet konvolučných vrstiev
- počet epoch
- použitie normalizácie dávok (batch normalization)
- veľkosť konvolučného jadra (kernel size)
- počet filtrov v prvej konvolučnej vrstve
- veľkosť vstupného obrazu
- rýchlosť učenia

Počet konvolučných vrstiev

Počet konvolučných vrstiev určuje hĺbku neurónovej siete. Vyšší počet vrstiev umožňuje modelu zachytiť komplexnejšie a abstraktnejšie príznaky, avšak zároveň zvyšuje riziko preučenia a výpočtovú náročnosť.

Počet epoch

Počet epoch predstavuje počet prechodov modelu cez celý tréningový dataset. Vyšší počet epoch môže zlepšiť presnosť modelu, avšak pri nadmernej hodnote môže dôjsť k preučeniu (overfittingu).

Normalizácia dávok (batch normalization)

Normalizácia dávok slúži na stabilizáciu a zrýchlenie procesu učenia. Normalizuje aktivácie jednotlivých vrstiev počas tréningu, čím znižuje citlivosť modelu na počiatočné nastavenia váh.

Veľkosť konvolučného jadra (kernel size)

Veľkosť konvolučného jadra určuje rozsah lokálneho okolia, z ktorého sa extrahujú príznaky. Menšie jadrá zachytávajú jemnejšie detaily, zatiaľ čo väčšie jadrá umožňujú zachytiť širšie kontextové informácie.

Počet filtrov v prvej vrstve

Počet filtrov určuje, koľko rôznych príznakov sa extrahuje v prvej konvulčnej vrstve. Vyšší počet filtrov zvyšuje kapacitu modelu, ale zároveň zvyšuje výpočtové nároky.

Veľkosť vstupného obrazu

Veľkosť vstupného obrazu ovplyvňuje množstvo dostupných informácií pre model. Väčšie rozlíšenie môže obsahovať viac detailov, ale zároveň zvyšuje výpočtovú záťaž.

Rýchlosť učenia

Rýchlosť učenia určuje rýchlosť aktualizácie váh počas tréningu. Príliš vysoká hodnota môže spôsobiť nestabilné učenie, zatiaľ čo príliš nízka hodnota môže spomaliť konvergenciu modelu.

4 Analýza súčasného stavu problematiky

Oblasť odhadu solárneho žiarenia na základe obrazových dát a meteorologických meraní v posledných rokoch výrazne napreduje, najmä vďaka rozvoju metód strojového a hlbokého učenia. Súčasný prístup sa líši použitými dátovými zdrojmi, architektúrami modelov, ako aj spôsobmi spracovania vstupných snímok. Spoločným cieľom týchto prístupov je zvýšenie presnosti predikcie a zníženie závislosti na klasických fyzikálnych modeloch. Nasledujúce práce predstavujú vybrané smery vývoja v tejto oblasti.

4.1 Prístup založený na transfer learningu a časových sekvenciách

Práca [26] sa zameriava na využitie hlbokého učenia s princípom transfer learningu, kde je model najprv trénovaný na všeobecných datasetoch a následne prispôbený pre konkrétnu lokalitu. Použité datasety zahŕňajú Sirta, DEWA a Stanford dataset, pričom vstupné snímky majú rozlíšenie 64×64 px.

Model pracuje s časovými sekvenciami, kde na základe posledných 15 minút (vzorkovanie v 2-minútových intervaloch) predikuje nasledujúcich 15 minút vývoja žiarenia. Na tréning je použitý optimalizátor Adam a normalizácia dát. Výkon modelu je vyhodnocovaný pomocou 10-násobnej krížovej validácie, pričom sa sleduje predovšetkým RMSE ako hlavná metrika presnosti. Súčasťou hodnotenia je aj výpočtová náročnosť modelu. Výstupom sú predikcie globálneho horizontálneho žiarenia (W/m^2).

4.2 Predikcia vývoja oblohy a odstránenie fisheye deformácie snímok

Práca [5] sa zameriava na predikciu vývoja oblohy pomocou TSI datasetu (Total Sky Imager), pričom kľúčovým problémom sú geometrické deformácie spôsobené fisheye objektívmi a hemisférickými zrkadlami. Tieto deformácie ovplyvňujú konzistenciu pixelovej reprezentácie rovnako veľkých oblakov, a tým aj ich konzistenciu pohybu, najmä v oblastiach blízko horizontu.

Autori navrhli uniformnú geometrickú deformáciu obrazu (z angl. *warping*), ktorá zjednocuje optický tok v obraze a zlepšuje konzistenciu pohybu oblakov naprieč scénou. Na modelovanie časového vývoja sa používajú sekvencie viacerých snímok, čím sa stabilizuje odhad pohybu.

Navrhnutá architektúra je založená na hlbokých neurónových sieťach, konkrétne U-Net a ConvLSTM variantoch (SkyNet). Modely sú trénované pomocou kombinácie stratových funkcií založených na intenzite, gradientoch a optickom toku. Výsledky ukazujú výrazný pokles presnosti pri absencii warping transformácie, čo potvrdzuje jej význam. Hodnotenie je realizované pomocou metriky PSNR.

PSNR (Peak Signal-to-Noise Ratio) je metrika používaná na vyhodnotenie kvality rekonštruovaného alebo predikovaného obrazu voči referenčnému obrazu. Vyjadruje pomer medzi maximálnou možnou hodnotou signálu a veľkosťou šumu (chyby) medzi obrazmi. Vyššia hodnota PSNR znamená vyššiu podobnosť medzi predikovaným a skutočným obrazom, teda lepšiu kvalitu predikcie.

Na rozdiel od našej práce sa táto štúdia primárne nezameriava na odhad solárneho žiarenia, ale na predikciu obrazovej sekvencie vývoja oblohy. Pritom rieši dôležitý problém spracovania fisheye snímok a geometrických deformácií, ktorý je priamo relevantný aj pre túto diplomovú prácu. Prístup založený na korekcii deformácie a analýze obrazových dát preto predstavuje významnú inšpiráciu, avšak v našej práci je zvolený jednoduchší a priamočiarejší prístup zameraný na predspracovanie vstupných snímok a regresný odhad žiarenia.

4.3 Kombinácia extrakcie príznakov a klasických metód

Práca [27] využíva rozsiahly dataset obsahujúci viac ako 350 000 snímok z obdobia 16 rokov, doplnený o merania globálneho horizontálneho žiarenia (GHI). Použité sú datasety TSI-880 a ASI-16.

Metodika je založená na dvojstupňovom prístupe: extrakcia príznakov a následná regresia. Vstupné snímky sú najprv konvertované a zmenšené na 32×32 RGB reprezentáciu, následne transformované do 1D vektorov.

Na regresiu sú použité klasické algoritmy strojového učenia, konkrétne Random Forest a K-Nearest Neighbors. Modely sú aplikované na nowcasting (krátkodobá predikcia v blízkej budúcnosti, z pravidla v rozsahu minút až desiatok minút) aj forecasting (dlhodobejšie predikcia, od desiatok minút až po hodiny) úlohy s rôznymi časovými horizontmi. Výkon je hodnotený pomocou RMSE a normalizovanej RMSE (nRMSE), čo umožňuje porovnanie naprieč rôznymi podmienkami.

4.4 Predikcia slnečného žiarenia pomocou CNN a LSTM sietí

Práca [290] sa venovala predikcii výkonu fotovoltaických panelov na základe celooblohových snímok a meteorologických dát. Autori využili dataset SkyCam a navrhli

viacero scenárov kombinujúcich konvolučné neurónové siete (CNN) a rekurentné siete typu LSTM pre spracovanie obrazových sekvencií a časových údajov.

LSTM siete sú určené na spracovanie sekvenčných dát a umožňujú modelu uchovávať informácie z predchádzajúcich časových krokov, vďaka čomu dokážu efektívne zachytávať časové zmeny a vývoj oblačnosti medzi jednotlivými snímkami.

Najlepšie výsledky dosiahlo riešenie využívajúce sekvenčné spracovanie snímok spolu s meteorologickými dátami pomocou siete LSTM, pričom dosiahnutá hodnota MAE bola 44.3 W/m^2 pre 15-minútové intervaly predikcie.

4.5 Zhrnutie a porovnanie analyzovaných riešení

Analyzované prístupy ukazujú tri hlavné smery vývoja v oblasti odhadu solárneho žiarenia.

1. Práca [26] využíva hlboké neurónové siete s časovou informáciou a transfer learningom na zlepšenie generalizácie.
2. Práca [5] sa zameriava na priestorovo-konzistentné spracovanie celooblohových snímok, najmä riešenie geometrických deformácií fisheye snímok a modelovanie časového vývoja pomocou sekvenčných architektúr.
3. Práca [27] kombinuje klasické metódy extrakcie príznakov so strojovým učením, pričom kladie dôraz na interpretovateľnosť a výpočtovú efektivitu.
4. Práca [28] kombinuje konvolučné neurónové siete (CNN) a siete typu LSTM na spracovanie sekvencií celooblohových snímok a meteorologických dát s cieľom zachytiť časové zmeny oblačnosti a ich vplyv na intenzitu žiarenia.

Spoločným znakom všetkých prístupov je využitie obrazových dát z celooblohových kamier a snaha o čo najpresnejšiu predikciu solárneho žiarenia. Zároveň sa ukazuje, že kvalita predspracovania, reprezentácia dát, časová informácia a voľba modelovej architektúry majú zásadný vplyv na výslednú presnosť modelu.

Na základe týchto poznatkov je v nasledujúcej časti práce navrhnutý vlastný prístup, ktorý kombinuje spracovanie fisheye snímok, konvolučné neurónové siete a optimalizačné metódy s cieľom dosiahnuť presnejší a robustnejší model pre odhad solárneho žiarenia.

5 Výber datasetu

Výber vhodného datasetu predstavuje kľúčový krok pri návrhu modelu pre odhad solárneho žiarenia. Vzhľadom na charakter riešenej úlohy musel dataset spĺňať nasledujúce požiadavky:

- Dataset zložený z celooblohových snímok, získaných širokouhlou kamerou typu fisheye, ktoré zachytávajú kompletnú hemisféru oblohy a poskytujú tak informácie o priestorovom rozložení oblačnosti.
- Dataset obsahujúci zodpovedajúce merania solárneho žiarenia priradené k jednotlivým snímkam v danom časovom okamihu, ktoré slúžia ako referenčné hodnoty pre tréning modelu.
- Dataset s dostatočným rozsahom, teda veľkým počtom vzoriek, ktorý zabezpečuje robustnosť modelu a jeho schopnosť generalizácie v rôznych podmienkach.

Na základe uvedených požiadaviek bol pre účely tejto práce zvolený dataset SkyCam.


5.1 SkyCam dataset

Dataset SkyCam, využitý v tejto práci, je dostupný na vyžiadanie prostredníctvom oficiálneho repozitára na platforme GitHub [29]. Poskytuje rozsiahlu kolekciu celooblohových snímok spolu so zodpovedajúcimi meraniami solárneho žiarenia, čím je vhodný pre úlohy krátkodobej predikcie solárneho žiarenia. Dataset bol zbieraný vo Švajčiarsku, v troch rôznych lokalitách:

- Neuchâtel
- Alpnach
- Bern

V každom časovom okamihu je pomocou širokouhlejšej kamery typu fisheye, zaznamenaná séria 13 snímok s rôznymi expozičnými časmi, ktoré sú následne spracované do jedného výsledného HDR (High Dynamic Range) obrazu. Pôvodné snímky majú rozlíšenie 1200×1200 pixelov, pričom výsledné HDR snímky majú rozlíšenie 600×600 pixelov. Celková veľkosť datasetu dosahuje približne 16 TB. Vizualizácia vzniku jednej finálnej snímky, pre jeden časový okamih, je viditeľná na obr. č. 15. Obr. č. 15 obsahuje všetky snímky vytvorené systémom dňa 29. januára 2018 o 11:09:20 na lokalite Alpnach. Prvých 13 snímok bolo zachytených sekvenčne s postupne narastajúcimi expozičnými

časmi. Posledná snímka predstavuje výsledný HDR (High Dynamic Range) obraz vytvorený následným spracovaním. Príklad umiestnenia kamery je znázornený na obr. č. 16.



Obr. 15: Príklad sekvencie 13 snímok s narastajúcou expozíciou. Posledný obrázok predstavuje finálnu HDR snímku, ktorá vznikla kombináciou predchádzajúcich snímok. [29].

Okrem obrazových dát dataset obsahuje aj presné merania solárneho žiarenia získané pomocou pyranometra typu Hukseflux SR30, ktorý je určený pre monitorovanie výkonu fotovoltických systémov a meteorologické aplikácie. Pyranometer meria globálne horizontálne žiarenie dopadajúce na rovinný povrch v jednotkách W/m^2 s uhlom záberu 180° . Príklad umiestnenia a použitia pyranometra je znázornený na obr. č. 16.



Obr. 16: Pyranometer (vľavo) a kamera (vpravo) použitá pri vytváraní SkyCam datasetu [29]

Vďaka kombinácii vysokofrekvenčných celoblokových snímok, rôznych expozičných úrovní a presných meraní žiarenia predstavuje dataset SkyCam vhodný základ pre návrh a testovanie modelov zameraných na krátkodobú predikciu solárneho žiarenia.

5.2 Úprava datasetu SkyCam pre potreby nášho modelu

V tejto práci boli využité iba snímky datasetu SkyCam zozbierané v lokalite Alpnach. Ich počet bol dostatočný na zabezpečenie požadovanej robustnosti modelu, pričom zároveň nepredstavoval nadmernú záťaž pre dostupné výpočtové prostriedky.

Použitý dataset pozostával z 33 067 snímok, s priradenými hodnotami solárneho žiarenia z pyranometra. Tento dataset bol rozdelený na tri pevné časti:

- trénovacia množina: 25 600 snímok
- validačná množina: 2 845 snímok
- testovacia množina: 4 622 snímok

6 Návrh a implementácia referenčného modelu pre odhad slnečného žiarenia

V tejto časti práce je opísaná implementácia referenčného modelu, ktorý predstavuje východiskový bod pre následné experimenty a umožňuje objektívne vyhodnocovať vplyv rôznych prístupov k spracovaniu vstupných dát. Implementácia modelu bola realizovaná v programovacom jazyku Python.

Trénovanie a experimenty boli realizované na výpočtovom zariadení vybavenom:

- **procesorom:** AMD Ryzen Threadripper PRO 5955WX (16 jadier)
- **grafickou kartou:** NVIDIA GeForce RTX 4090.

6.1 Návrh vlastnej konvolučnej neurónovej siete

Navrhnutý referenčný model je založený na konvolučnej neurónovej sieti, ktorá je optimalizovaná pre regresnú úlohu odhadu intenzity slnečného žiarenia zo vstupných obrazových dát. Model bol navrhnutý tak, aby umožňoval flexibilné experimentovanie s architektúrou a zároveň bol dostatočne efektívny z hľadiska výpočtových nárokov.

6.1.1 Vstup a predspracovanie dát

Vstupom do modelu sú celooblohové snímky, ktoré sú pred samotným spracovaním upravené pomocou štandardizovaného postupu predspracovania. Tento proces zahŕňa zmenu veľkosti obrazov na jednotnú dimenziu, konverziu farebného priestoru a následnú normalizáciu hodnôt pixelov (bližšie popísané v kapitole 3). V prípade potreby je možné pracovať aj s vybraným kanálom obrazu alebo vykonať transformáciu do alternatívneho farebného priestoru.

6.1.2 Generovanie dát a spracovanie dávok

Z dôvodu pamäťových obmedzení nie sú dáta vo finálnom modeli spracovávané ako celá množina naraz, ale pomocou dátových generátorov, ktoré zabezpečujú dynamické načítavanie a spracovanie obrazov po dávkach. Ďalším krokom optimalizácie bolo implementovanie techniky zmiešanej presnosti (z angl. Mixed Precision), pri ktorej sa časť výpočtov realizuje vo formáte float16 namiesto štandardného float32. Formát float16 využíva 16 bitov na reprezentáciu reálnych čísel, zatiaľ čo float32 využíva 32 bitov, čo vedie k približne polovičnej pamäťovej náročnosti pri float16. Tento prístup znižuje množstvo

pamäte potrebnej na uloženie dát počas tréningu a umožnil efektívnejšie spracovanie väčších vstupných obrazov.

Dáta boli rozdelené na trénovaciu a validačnú množinu, pričom testovacia množina bola spracovaná samostatne. Pri trénovaní sa používala pevne definovaná veľkosť dávky.

6.1.3 Konvolučná časť siete

Jadro modelu tvorí sekvenčná konvolučná architektúra pozostávajúca z viacerých konvolučných vrstiev. Každá konvolučná vrstva aplikuje množinu filtrov na vstupné dáta s cieľom extrahovať lokálne vizuálne príznaky, ako sú hrany, textúry a štruktúry oblačnosti.

Počet konvolučných vrstiev predstavuje konfigurovateľný parameter, pričom s každou ďalšou vrstvou sa počet filtrov postupne navyšuj. Tento prístup umožňuje modelu extrahovať čoraz komplexnejšie obrazové príznaky vo vyšších vrstvách siete. Koeficient rastu počtu filtrov bol nastavený na hodnotu 1,2 a zároveň bol maximálny počet filtrov explicitne obmedzený na hodnotu 256, aby sa predišlo nadmerným pamäťovým nárokom a problémom s nedostatkom grafickej pamäte počas tréningu modelu.

Počas experimentov sa ukázalo, že pri hlbších architektúrach obsahujúcich väčší počet konvolučných vrstiev dochádzalo pri menších vstupných rozlíšeniach k príliš rýchlej redukcii rozmerov máp príznakov. Pri aplikovaní pooling vrstvy po každej konvolučnej vrstve sa priestorové rozmery vstupných dát zmenšovali príliš rýchlo, čo viedlo k strate dôležitých vizuálnych informácií ešte pred spracovaním vo vyšších vrstvách siete. Tento problém bol riešený aplikovaním pooling vrstiev až po každej druhej konvolučnej vrstve, čím sa spomalila redukcia rozlíšenia máp príznakov a zachovalo sa dostatočné množstvo priestorových informácií potrebných na extrakciu relevantných príznakov.

6.1.4 Normalizačné a aktivačné mechanizmy

V modeli je možné voliteľne použiť normalizáciu dávok, ktorá stabilizuje priebeh učenia a zrýchľuje konvergenciu. Aktivačná funkcia ReLU je použitá po konvolučných operáciách a zavádza nelinearitu do modelu, čím umožňuje učenie komplexných vzťahov v dátach.

6.1.5 Husto prepojená časť siete

Na konci konvolučnej časti sa výstup transformuje do jednorozmernej reprezentácie pomocou operácie sploštenia. Následne nasleduje plne prepojená vrstva, ktorá spracúva extrahované príznaky. Výstupná vrstva obsahuje jeden neurón s lineárnou aktiváciou, keďže ide o regresnú úlohu.

6.1.6 Tréning modelu

Model je optimalizovaný pomocou algoritmu Adam s nastavenou rýchlosťou učenia ako konfigurovateľným parametrom. Ako stratová funkcia je použitá stredná kvadratická chyba pričom ako doplnková metrika je sledovaná stredná absolútna chyba.

6.2 Manuálna predbežná optimalizácia hyperparametrov

6.2.1 Popis experimentu

Pred aplikáciou automatizovanej optimalizácie hyperparametrov bolo potrebné získať základný prehľad o správaní navrhnutej architektúry a identifikovať parametre, ktoré majú najvýraznejší vplyv na výkon modelu. Z tohto dôvodu bola realizovaná predbežná experimentálna analýza, pri ktorej boli jednotlivé hyperparametre testované postupne. V rámci každého experimentu bolo otestovaných viacero hodnôt daného parametra, pričom najlepšia z nich bola následne fixovaná a použitá pri testovaní ďalšieho parametra. Najskôr bol analyzovaný vplyv počtu konvolučných vrstiev, následne bol pri najlepšej architektúre testovaný prínos normalizácie dávok, ďalej veľkosť konvolučných jadier a napokon veľkosť vstupných obrazov. Tento sekvenčný prístup umožnil izolovať vplyv jednotlivých parametrov bez súčasnej zmeny viacerých premenných naraz.

Pre každý experiment boli zaznamenané metriky RMSE, MAE a R^2 na trénovacej, validačnej a testovacej množine. Súčasne boli ukladané aj grafy krivky učenia zobrazujúce priebeh stratovej funkcie a metriky MAE počas tréningu, čo umožnilo vizuálne analyzovať stabilitu učenia modelu, identifikovať prípadné prejavy preučenia a vytvoriť kvalitný základ pre následnú optimalizáciu pomocou nástroja Optuna.

6.2.2 Výsledky experimentu


Na základe realizovaných experimentov boli identifikované predbežné hodnoty hlavných hyperparametrov referenčného modelu.

- Najlepšie výsledky dosiahol stredný počet konvolučných vrstiev: 6.
- Aktívna normalizácia dávok mala výrazne pozitívny vplyv na výkon modelu. Konkrétne došlo k významnému zníženiu hodnôt RMSE a MAE na trénovacej aj validačnej množine, čo poukazuje na stabilnejší priebeh učenia.
- Jadro s rozmerom 7×7 dosiahlo najlepšie výsledky, najmä z pohľadu presnosti na testovacej množine.

- Významný vplyv bol pozorovaný pri zmene veľkosti vstupných snímok. Menšie rozlíšenie 128×128 pixelov poskytlo stabilné a konzistentné výsledky, zatiaľ čo väčšie rozlíšenia, najmä 640×640 pixelov, viedli k výraznému zhoršeniu metrík. Podrobné výsledky jednotlivých experimentov sú uvedené v Tabuľke 1.

Tabuľka 1: Výsledky manuálnej optimalizácie hyperparametrov

Parameter	Hodnota	Train RMSE (W/m ²) / MAE (W/m ²)	Val RMSE (W/m ²) / MAE (W/m ²)	Test RMSE (W/m ²) / MAE (W/m ²) / R ²
Počet vrstiev	3	38.25 / 22.53	48.01 / 30.62	48.75 / 30.84 / 0.970
	6	39.07 / 25.57	39.05 / 25.76	39.17 / 25.74 / 0.980
	9	41.59 / 26.11	41.14 / 25.65	40.62 / 25.52 / 0.979
Vybrané	6	39.07 / 25.57	39.05 / 25.76	39.17 / 25.74 / 0.980
Normalizácia dávok	Vypnutá	42.16 / 27.19	41.60 / 28.03	41.69 / 27.98 / 0.978
	Zapnutá	18.80 / 12.38	27.88 / 18.87	27.33 / 18.47 / 0.990
Vybrané	Zapnutá	18.80 / 12.38	27.88 / 18.87	27.33 / 18.47 / 0.990
Veľkosť jadra	(3,3)	19.47 / 12.71	22.19 / 16.70	22.53 / 16.68 / 0.994
	(5,5)	21.01 / 13.81	27.55 / 19.07	27.46 / 18.89 / 0.990
	(7,7)	17.17 / 11.64	17.38 / 11.72	17.59 / 11.82 / 0.996
Vybrané	(7,7)	17.17 / 11.64	17.38 / 11.72	17.59 / 11.82 / 0.996
Veľkosť obrázku	(128,128)	21.98 / 14.06	18.31 / 11.45	18.16 / 11.52 / 0.996
	(224,224)	20.25 / 13.53	18.46 / 12.12	18.79 / 12.32 / 0.995
	(480,480)	27.41 / 18.56	41.40 / 30.94	41.38 / 30.80 / 0.978
	(640,640)	20.64 / 13.63	331.05 / 208.87	331.75 / 209.45 / -0.403
Vybrané	(128,128)	21.98 / 14.06	18.31 / 11.45	18.16 / 11.52 / 0.996



Obr. 17: Graf popisujúci priebeh učenia CNN s najlepším nastavením hyperparametrov podľa výsledkov z manuálnej optimalizácie hyperparametrov

Na grafe na obr. č. 17 vidno, že krivka učenia ukazuje, že tréningová strata (MSE) začína približne na hodnote 30 000 a veľmi rýchlo klesá už v prvej epoche, čo naznačuje, že sieť okamžite začína zachytávať základné vzory v dátach. Postupne sa znižuje až do približne 6. epochy, kde sa stabilizuje na nízkej hodnote, čo indikuje konvergenciu modelu.

Strata na validačných dátach začína vyššie, nad 150 000, ale už v prvej epoche sa výrazne znižuje a k 3. epoche klesá približne na 25 000. Od 4. epochy sa validačná strata približuje tréningovej strate a od 6. epochy ostáva na rovnakej úrovni, čo svedčí o dobrej generalizácii modelu.

Celková interpretácia krivky učenia naznačuje, že model sa učí veľmi rýchlo a efektívne, pričom nedochádza k pretrénovaniu.

6.2.3 Záver experimentu

Na základe predbežnej manuálnej optimalizácie hyperparametrov bolo identifikované nasledujúce nastavenie referenčného modelu:

- počet vrstiev: 6
- použitie normalizácie dávok: áno
- veľkosť jadra: 7×7
- veľkosť vstupných snímok: 128×128

Tieto hodnoty boli následne použité ako východiskové nastavenie pri finálnej optimalizácii hyperparametrov pomocou framework-u Optuna.

6.3 Optimalizácia hyperparametrov pomocou Optuna

6.3.1 Popis experimentu

Cieľom tejto časti experimentu bolo zlepšiť výkonnosť navrhnutého referenčného modelu. Po počiatočnom manuálnom ladení architektúry modelu bolo zrejmé, že výber hyperparametrov má výrazný vplyv na kvalitu výsledkov, najmä na hodnotu validačnej chyby RMSE.

Hlavnou myšlienkou bolo automatizovať proces hľadania optimálnej konfigurácie modelu prostredníctvom systematického prehľadávania priestoru hyperparametrov. Na tento účel bol zvolený framework Optuna. Optuna je bližšie popísaná v kapitole 7, resp. 7.1.

Optimalizované hyperparametre zahŕňali:

- počet konvolučných vrstiev
- počet filtrov v prvej vrstve
- veľkosť konvolučného jadra
- použitie alebo nepoužitie normalizácie dávok
- veľkosť vstupného obrazu
- počet tréningových epoch
- rýchlosti učenia

Jednotlivé hyperparametre sú bližšie popísané v kapitole 7, resp. 7.2.

Ako optimalizačné kritérium bola zvolená validačná chyba RMSE, ktorú sa snažil algoritmus minimalizovať. Dôvodom bolo zabezpečiť čo najlepšiu generalizáciu modelu na neznáme dáta, pričom testovacia množina bola použitá až po výbere najlepších hyperparametrov.

Celkovým cieľom teda nebolo iba dosiahnuť najnižšiu možnú tréningovú chybu, ale nájsť takú konfiguráciu modelu, ktorá poskytne stabilné a presné výsledky aj na validačných a testovacích dátach.

6.3.2 Optimalizácia pamäťovej náročnosti

Počas rozširovania počtu pokusov v rámci optimalizácie pomocou knižnice Optuna začalo dochádzať k opakovaným chybám vyčerpania systémovej pamäte, tzv. OOM (z angl. *Out Of Memory*). Tieto chyby vznikali najmä pri kombináciách väčších vstupných rozlíšení, vyššieho počtu konvolučných vrstiev a väčšieho počtu filtrov. Problém sa prejavoval náhlým ukončením tréningu počas epochy bez explicitnej chyby, prípadne zlyhaním celého experimentu.

Na stabilizáciu experimentu a efektívnejšie využitie GPU pamäte boli postupne implementované nasledujúce kroky:

- uvoľnenie pamäte medzi pokusmi
- adaptívna veľkosť dávky
- ukončenie pokusov s rizikovými kombináciami hyperparametrov (prerezávanie)
- obmedzenie rastu počtu filtrov v konvolučných vrstvách

Uvoľnenie pamäte medzi pokusmi

Na začiatok objektívnej funkcie bolo pridané:

```
import tensorflow as tensorflow
import gc

tensorflow.keras.backend.clear_session()
gc.collect
```

Týmto sa po každom pokuse odstránili zvyšky grafu modelu z pamäte a zároveň sa spustil zberač „odpadu“ (z angl. *garbage collector*) jazyka Python, ktorý uvoľňuje nepoužívané objekty z pamäte. Cieľom bolo zabrániť postupnému zaplňaniu pamäte pri veľkom počte pokusov.

Adaptívna veľkosť dávky

Veľkosť dávky bola navrhnutá dynamicky v závislosti od rozlíšenia vstupného obrazu. Pri väčších obrázkoch bola použitá menšia hodnota, čím sa znížila okamžitá pamäťová náročnosť tréningu.

Tabuľka 2: Priradenie veľkosti dávky v závislosti od rozlíšenia vstupného obrazu z dôvodu optimalizácie pamäťovej náročnosti

Rozlíšenie vstupného obrazu (px)	Priradená veľkosť dávky
$\leq 128 \times 128$	32
$129 \times 129 - 224 \times 224$	16
$225 \times 225 - 512 \times 512$	8
$513 \times 513 - 1024 \times 1024$	1
$> 1024 \times 1024$	1

Tento krok mal významný vplyv na stabilitu tréningu pri vyšších rozlíšeníach.

Ukončenie pokusov s rizikovými kombináciami hyperparametrov

Boli identifikované kombinácie hyperparametrov, ktoré s vysokou pravdepodobnosťou viedli k OOM chybám (napr. vysoké rozlíšenie + veľký počet vrstiev + vysoký počet filtrov). Do objektívnej funkcie boli preto pridané podmienky, ktoré takéto kombinácie automaticky ukončili.

Tabuľka 3: Podmienky a dôvody predčasného ukončenia pokusov Optuna z dôvodu optimalizácie pamäťovej náročnosti

Podmienka	Dôvod ukončenia
veľkosť obrázku = 256×256 AND počet filterov ≥ 32 AND počet vrstiev ≥ 7	Vysoké riziko preťaženia GPU pamäte
veľkosť obrázku = 256×256 AND veľkosť jadra = 7×7 AND počet vrstiev ≥ 6	Veľké konvolučné jadrá pri vyššom počte vrstiev výrazne zvyšujú pamäťové nároky
veľkosť obrázku = 256×256 AND normalizácia dávok = zapnutá AND počet vrstiev ≥ 8	Normalizácia dávok vo väčšej architektúre zvyšuje spotrebu pamäte
veľkosť obrázku = 256×256 AND počet epoch ≥ 12 AND počet vrstiev ≥ 8	Dlhé trénovanie hlbokých modelov s veľkým vstupom zvyšuje riziko OOM
počet filterov = 128 AND počet vrstiev ≥ 4	Príliš vysoký počet filtrov vedie k exponenciálnemu rastu parametrov

Obmedzenie rastu počtu filtrov v konvolučných vrstvách

V pôvodnej implementácii sa počet filtrov v konvolučných vrstvách postupne zvyšoval pomocou rastového koeficientu, čo je bežný prístup pri návrhu CNN architektúr. Pri väčšom počte vrstiev však tento mechanizmus viedol k výraznému nárastu pamäťových nárokov, najmä v kombinácii s vyšším rozlíšením vstupných snímok, čo spôsobovalo chyby nedostatku pamäte.

Z tohto dôvodu bol koeficient rastu znížený z 1,5 na 1,2 a zároveň bol maximálny počet filtrov obmedzený na hodnotu 256. Toto obmedzenie stabilizovalo pamäťové nároky modelu a umožnilo efektívnejšie testovanie rôznych konfigurácií architektúry.

6.3.3 Definícia priestoru hyperparametrov

Tabuľka 4: Definícia priestoru hyperparametrov pre optimalizáciu modelu pomocou frameworku Optuna

Hyperparameter	Typ výberu	Testované hodnoty / Rozsah
Počet konvolučných vrstiev	Celé číslo	3 – 9
Počet epoch	Celé číslo	5 – 15
Normalizácia dávok	Kategorizovaná	True / False
Veľkosť jadra (kernel)	Kategorizovaná	3×3 , 5×5 , 7×7
Počet filtrov (1. vrstva)	Kategorizovaná	16, 32, 64, 128
Veľkosť vstupného obrazu	Kategorizovaná	128×128 , 256×256
Rýchlosť učenia	Spojité (log)	$1e-5$ – $1e-2$ (logaritmická škála)

V tabuľke sú uvedené typy hyperparametrov a spôsob ich výberu. Diskrétné (celé) parametre nadobúdajú iba celé číselné hodnoty z daného intervalu, spojité parametre sú vyberané z určitého intervalového rozsahu reálnych hodnôt a kategorizované parametre predstavujú výber z vopred definovanej množiny možností. Tento spôsob definovania priestoru hyperparametrov umožňuje systematické a efektívne prehľadávanie možných konfigurácií modelu.

6.3.4 Priebeh experimentu

Optimalizačný proces prebiehal postupne v niekoľkých fázach, pričom sa postupne rozširoval počet pokusov a upravovala sa konfigurácia systému s cieľom dosiahnuť lepší výkon modelu a zároveň zabrániť pamäťovým chybám (OOM).

1. Inicializačný test – 1 pokus bez optimalizácie pamäte

Na začiatku bol vykonaný jeden testovací beh s jednou konfiguráciou hyperparametrov. Cieľom bolo overiť funkčnosť celého pipeline procesu (tréning, validácia, testovanie). Model dosiahol validačnú RMSE približne 24.54, pričom testovacia RMSE bola 15.80. Tento krok slúžil najmä ako kontrola správnosti implementácie.

2. 15 pokusov – bez optimalizácie pamäte

V ďalšej fáze prebehlo 15 optimalizačných pokusov bez špecifických opatrení proti OOM a bez zahrnutia počtu epoch medzi optimalizované parametre. Výsledky sa výrazne zlepšili,

najlepšia validačná RMSE klesla na približne 12.83 a testovacia RMSE na 12.74. Tento krok potvrdil, že optimalizácia hyperparametrov má významný vplyv na výkon modelu.

3. 30 pokusov – bez optimalizácie pamäte

V tejto fáze sa začali objavovať problémy s nedostatkom pamäte (OOM). To viedlo k implementácii viacerých pamäťových optimalizácií, spomínaných v kapitole 10.3.2.

4. 45 pokusov – optimalizované nastavenie

V tejto fáze sa dosiahol najlepší výsledok celého experimentu – validačná RMSE približne 12.33 W/m² a testovacia RMSE 13.22 W/m². Táto konfigurácia bola následne použitá ako finálny model.

5. 60 pokusov – optimalizované nastavenie

Posledným pokusom bolo zvýšenie počtu pokusov na 60 pri zachovaní ukončovania. Aj napriek optimalizáciám však došlo k OOM chybe, čo naznačuje, že ďalšie zvyšovanie počtu pokusov už nebolo z hľadiska stability systému vhodné, najmä vzhľadom na hardvérové obmedzenia použitého výpočtového prostredia.


6.3.5 Výsledky experimentu

Zo všetkých realizovaných experimentov sa ako najrelevantnejšie ukázali výsledky pri 30 pokusoch a 45 pokusoch.


Tabuľka 5: Výsledky nanovo natrénovaných modelov s hyperparametrami z 30 a 45 pokusov optimalizácie pomocou frameworku Optuna

Počet pokusov	Val RMSE (W/m ²)	Test RMSE (W/m ²)	Test MAE (W/m ²)	R ²
30 pokusov	14.92	13.52	8.54	0.998
45 pokusov	14.00	13.22	8.38	0.998

Z tabuľky vyplýva, že konfigurácia získaná pri 45 pokusoch dosiahla mierne lepšie validačné aj testovacie výsledky, pričom rozdiel nie je výrazný, ale je konzistentný v prospech 45 pokusov.



Obr. 18: Graf popisujúci priebeh učenia nanovo natrénovaného modelu s parametrami z 30 pokusov optimalizácie pomocou frameworku Optuna



Obr. 19: Graf popisujúci priebeh učenia nanovo natrénovaného modelu s parametrami z 45 pokusov optimalizácie pomocou frameworku Optuna

Pri konfigurácii z 30 pokusov je možné pozorovať stabilný pokles tréningovej aj validačnej chyby počas prvých epoch, pričom ku koncu tréningu dochádza k miernemu kolísaniu validačnej krivky. Tréningová chyba je mierne nižšia než validačná, čo naznačuje dobré prispôsobenie modelu bez výrazného preučenia.

V prípade 45 pokusov je priebeh učenia taktiež stabilný, avšak konvergencia je mierne rýchlejšia a rozdiel medzi tréningovou a validačnou stratou zostáva relatívne malý. Validácia vykazuje menšie výkyvy a finálna hodnota chyby je nižšia než pri 30 pokusoch. Krivky naznačujú vyvážený model s dobrou generalizačnou schopnosťou.

6.3.6 Záver experimentu

Porovnaním numerických výsledkov a priebehu učenia bola ako finálna konfigurácia zvolená architektúra získaná pri 45 pokusoch.

Tabuľka 6: Optimálne nastavenie hyperparametrov podľa optimalizácie pomocou frameworku Optuna (použité v ďalších experimentoch)

Parameter	Hodnota
Počet vrstiev	4
Počet epoch	14
Normalizácia dávok	Vypnutá
Veľkosť jadra	5×5
Počet filtrov (1. vrstva)	32
Veľkosť vstupu	256×256
Rýchlosť učenia	0.0002035

Na základe uvedených výsledkov možno konštatovať, že optimalizácia pomocou frameworku Optuna priniesla výrazné zlepšenie oproti pôvodnému nastaveniu a umožnila nájsť stabilnú konfiguráciu modelu s vysokou presnosťou predikcie globálneho slnečného žiarenia.

7 Návrh scenárov predspracovania fisheye snímok

V predchádzajúcej kapitole bol navrhnutý a optimalizovaný referenčný model, ktorý slúži ako východiskový bod pre ďalšie experimenty. Na to nadväzuje návrh scenárov predspracovania fisheye snímok, ktorých cieľom je analyzovať vplyv rôznych úprav vstupných dát na presnosť predikcie solárneho žiarenia. Na rozdiel od predchádzajúcich krokov, kde bol dôraz kladený na architektúru modelu a jeho hyperparametre, sa táto kapitola zameriava na systematické testovanie jednotlivých prístupov k spracovaniu obrazových dát.

V rámci experimentov sú porovnávané nasledovné scenáre:

- analýza farebných priestorov a obrazových kanálov
- orezanie a maskovanie snímok
- úpravy geometrického skreslenia spôsobeného fisheye kamerou

Výsledky jednotlivých prístupov sú následne vyhodnocované voči referenčnému modelu, čo umožňuje identifikovať najvhodnejšie predspracovacie techniky pre danú úlohu.

7.1 Analýza vplyvu farebného priestoru a jednotlivých kanálov

7.1.1 Popis experimentu

V rámci tohto experimentu bola realizovaná analýza vplyvu farebných priestorov a jednotlivých obrazových kanálov na presnosť predikcie globálneho slnečného žiarenia. Cieľom bolo identifikovať, ktoré farebné reprezentácie a ich zložky nesú najrelevantnejšiu informáciu pre danú úlohu.

Experiment zahŕňal testovanie viacerých farebných priestorov, konkrétne RGB, HSV a YCrCb (jednotlivé farebné priestory sú bližšie popísané v kapitole 3, resp. 3.1.2 – 3.1.6). V rámci každého z nich bol model trénovaný s využitím jednotlivých kanálov samostatne, ako aj s využitím všetkých kanálov súčasne. Tento prístup umožnil posúdiť prínos jednotlivých zložiek obrazu, ako aj celkovej farebnej reprezentácie.

Na zvýšenie spoľahlivosti výsledkov boli jednotlivé experimenty opakované viackrát, pričom výsledné hodnoty metrík boli spriemerované

7.1.2 Zdôvodnenie nezahrnutia farebného priestoru CMYK

Farebný priestor CMYK nebol do experimentu zahrnutý, keďže ide o subtraktívny farebný model primárne určený pre tlačové technológie. Na rozdiel od RGB, HSV alebo YCrCb nejde o reprezentáciu prirodzene spätú so snímačmi digitálnych kamier, ktoré zaznamenávajú obraz v aditívnom RGB modeli. Transformácia do priestoru CMYK by preto predstavovala dodatočný umelý krok bez priamej fyzikálnej súvislosti s procesom snímania obrazu, čo by mohlo viesť k ťažšie interpretovateľným výsledkom bez jasného prínosu pre analyzovaný problém.

7.1.3 Metodika experimentu

Ako základ bol použitý referenčný model s hyperparametrami určenými v optimalizačnej fáze pomocou nástroja Optuna. Tým sa zabezpečilo, že rozdiely vo výsledkoch sú spôsobené výlučne zmenou farebnej reprezentácie vstupu.

Tabuľka 7: Nastavenie modelu pre testovanie vplyvu farebných priestorov a jednotlivých farebných kanálov

Parameter	Hodnota
Počet vrstiev	4
Počet epoch	14
Normalizácia dávok	Vypnutá
Veľkosť jadra	5×5
Počet filtrov (1. vrstva)	32
Veľkosť vstupu	256×256
Rýchlosť učenia	0.0002035

Pre každý farebný priestor (RGB, HSV a YCrCb) bol model trénovaný v dvoch režimoch. V prvom prípade bol použitý vždy iba jeden farebný kanál, pričom ostatné boli nulované, čo umožnilo vyhodnotiť jeho individuálny prínos. V druhom prípade bol model trénovaný s využitím všetkých troch kanálov súčasne. Každé trénovanie bolo opakované 3-krát a výsledné metriky boli spriemerované s cieľom zvýšiť spoľahlivosť výsledkov.

7.1.4 Výsledky experimentu

Nasledujúce tabuľky prezentujú priemerné hodnoty metrík RMSE, MAE a koeficientu determinácie R^2 na testovacej množine, vypočítané ako priemer z troch nezávislých behov

modelu. Rozdiely medzi jednotlivými behmi boli relatívne malé, čo potvrdzuje stabilitu tréningového procesu.

Tabuľka 8: Priemerné výsledky z troch behov pre jednotlivé kanály RGB farebného priestoru

Kanál	RMSE (W/m ²)	MAE (W/m ²)	R ²
R	13,84	8,63	0,997
G	13,75	8,29	0,997
B	16,78	10,95	0,996

Tabuľka 9: Priemerné výsledky z troch behov pre jednotlivé kanály HSV farebného priestoru

Kanál	RMSE (W/m ²)	MAE (W/m ²)	R ²
H	20,80	12,82	0,994
S	18,64	11,36	0,995
V	14,00	8,84	0,998

Tabuľka 10: Priemerné výsledky z troch behov pre jednotlivé kanály YCrCb farebného priestoru

Kanál	RMSE (W/m ²)	MAE (W/m ²)	R ²
Y	13,13	7,80	0,998
Cr	20,67	12,64	0,994
Cb	21,32	13,56	0,994

Tabuľka 11: Priemerné výsledky z troch behov pre jednotlivé farebné priestory


Farebný priestor	RMSE (W/m ²)	MAE (W/m ²)	R ²
RGB	13,66	8,14	0,998
HSV	11,99	7,11	0,998
YCrCb	12,91	7,94	0,998

V rámci farebného priestoru RGB dosahovali kanály R a G v priemere veľmi podobné výsledky, pričom ich hodnoty RMSE a MAE boli mierne nižšie než v prípade kanála B.


V priestore HSV vykazoval najnižšie chyby kanál V, zatiaľ čo kanál H dosahoval najvyššie hodnoty RMSE a MAE.

V prípade farebného priestoru YCrCb dosahoval najlepšie výsledky kanál Y, zatiaľ čo chrominančné zložky Cr a Cb vykazovali výrazne vyššie chyby.


Pri porovnaní plných farebných priestorov dosiahol najnižšiu priemernú hodnotu RMSE model trénovaný v priestore HSV.




Obr. 20: Grafy reprezentujúce výsledky troch behov analýzy kanálov farebného priestoru RGB



Obr. 21: Grafy reprezentujúce výsledky troch behov analýzy kanálov farebného priestoru HSV




Obr. 22: Grafy reprezentujúce výsledky troch behov analýzy kanálov farebného priestoru YCrCb



Obr. 23: Grafy reprezentujúce výsledky troch behov analýzy celých farebných priestorov

7.1.5 Záver experimentu

Výsledky ukázali, že pri použití všetkých troch kanálov dosiahol najnižšiu priemernú hodnotu chyby model trénovaný vo farebnom priestore HSV. Zároveň sa nepreukázalo, že by niektorý z jednotlivých kanálov v testovaných farebných priestoroch dosahoval lepšie výsledky než kompletná reprezentácia HSV. Na základe týchto zistení bol farebný priestor HSV zvolený ako preferovaná vstupná reprezentácia pre ďalšie experimenty.




Obr. 24: Vzorový snímok z datasetu zobrazený v HSV farebnom priestore

7.2 Orezanie a maskovanie snímok

7.2.1 Popis experimentu

Cieľom tohto experimentu bolo preskúmať vplyv orezania snímok z kamery typu fisheye na presnosť predikcie solárneho žiarenia pomocou konvolučnej neurónovej siete. Pôvodné snímky majú štvorcový tvar, pričom samotný zachytený obraz je kruhový. V rohoch a na okrajoch sa preto nachádzajú oblasti bez relevantných informácií, reprezentované čiernymi pixelmi.



Obr. 25: Vzorový snímok z datasetu bez orezania a bez maskovania

7.2.2 Metodika experimentu


Ako základ bol použitý referenčný model s hyperparametrami určenými pomocou nástroja Optuna, pričom bol použitý farebný priestor HSV na základe predchádzajúcich výsledkov.

Tabuľka 12: Nastavenie modelu pre testovanie vplyvu orezania a maskovania snímok

Parameter	Hodnota
Počet vrstiev	4
Počet epoch	14
Normalizácia dávok	Vypnutá
Veľkosť jadra	5×5
Počet filtrov (1. vrstva)	32
Veľkosť vstupu	256×256
Rýchlosť učenia	0.0002035
Farebný priestor	HSV

Experiment bol realizovaný v dvoch variantoch. V prvom prípade bol model trénovaný na orezaných snímkach, kde bol každý obrázok upravený na štvorcový výrez obsahujúci celý kruhový obraz. V druhom variante bolo k orezaniu pridané aj maskovanie, pri ktorom boli oblasti mimo kruhu odstránené a nahradené priemernou farebnou hodnotou snímky. Každý z variantov bol trénovaný trikrát a výsledné metriky boli spriemerované s cieľom zvýšiť spoľahlivosť výsledkov.

Kľúčovým krokom úpravy bolo určenie polomeru kruhového obrazu. Tento polomer bol primárne odhadovaný dynamicky pre každý obrázok na základe detekcie najvzdialenejších nečiernych pixelov od stredu snímky. V prípadoch, keď takýto odhad nebol možný (napríklad pri veľmi tmavých snímkach), bol použitý referenčný polomer. Ten bol získaný analýzou sekvencie snímok datasetu, pričom sa vybral prvý obrázok, ktorý nebol výrazne ovplyvnený nedostatočnými svetelnými podmienkami. Tento referenčný polomer bol následne použitý pre všetky snímky, pri ktorých nebolo možné spoľahlivo určiť polomer dynamicky.



Obr. 26: Príklad orezaného snímku (vľavo) a orezaného snímku s aplikovanou maskou – čierne oblasti nahradené priemernou farbou snímky(vpravo)

7.2.3 Výsledky experimentu

Tabuľka 13: Priemerné výsledky analýzy vplyvu orezávania a maskovania vstupných snímok

Prístup spracovania obrázkov	Počet behov	Test RMSE (W/m ²)	Test MAE (W/m ²)	Test R ²
<i>Bez orezania a bez maskovania</i>	3	12.54	7.41	0.998
Iba orezanie obrázka	3	12.86	8.32	0.997
Orezanie + kruhová maska	3	12.08	7.18	0.998

Z výsledkov vyplýva, že samotné orezanie obrázkov neprinieslo zlepšenie presnosti modelu a v priemere viedlo dokonca k mierne vyšším hodnotám chýb v porovnaní s referenčným prístupom. Naopak, kombinácia orezania obrázka a aplikácie kruhovej masky dosiahla najnižšie hodnoty RMSE aj MAE, čo naznačuje lepšiu schopnosť modelu generalizovať na testovacích dátach. Koeficient determinácie R^2 zostal vo všetkých prípadoch veľmi vysoký, čo potvrdzuje celkovo dobrú predikčnú schopnosť modelu.

7.2.4 Záver experimentu

Výsledky ukázali, že samotné orezanie obrázkov neprináša zlepšenie presnosti modelu. Naopak, kombinácia orezania a kruhového maskovania dosiahla v priemere najnižšie hodnoty RMSE aj MAE. Rozdiely medzi jednotlivými prístupmi sú však relatívne malé, čo naznačuje, že pri väčšom počte behov tréningu by sa priemerné výsledky mohli mierne zmeniť a rozdiel medzi jednotlivými prístupmi by sa mohol ešte zmenšiť alebo úplne vyrovnať. Z praktického hľadiska by tak bolo možné uvažovať aj o použití pôvodných obrázkov bez úprav, keďže v mnohých jednotlivých behoch boli výsledky veľmi podobné.

V rámci vykonaných experimentov ukázalo, že najlepší jednotlivý výsledok, ktorý zároveň predstavoval najväčšie zlepšenie oproti referenčnému prístupu, bol dosiahnutý pri použití kombinácie orezania a kruhovej masky. Na základe tejto skutočnosti a priemerných výsledkov bol preto v ďalších experimentoch práce použitý predspracovací postup kombinujúci orezanie obrázka a aplikáciu kruhovej masky ako štandardná metóda spracovania vstupných dát.

7.3 Úpravy geometrického skreslenia spôsobeného fisheye kamerou

7.3.1 Popis experimentu

Snímky získané pomocou fisheye kamery obsahujú výrazné geometrické skreslenie, ktoré spôsobuje nelineárne zobrazenie priestoru, najmä v oblastiach vzdialených od stredu obrazu. Toto skreslenie ovplyvňuje tvar, veľkosť aj pohyb oblakov, čím môže negatívne ovplyvniť schopnosť modelu správne extrahovať relevantné príznaky. Problematika je viac popísaná v kapitole 2, resp. 2.1 a 2.2.

Cieľom tejto časti bolo preskúmať, či úprava alebo odstránenie tohto geometrického skreslenia vedie k zlepšeniu presnosti predikcie. Na rozdiel od prístupu popísaného v práci [5], popísanej v kapitole 8.2, ktorý využíva komplexnejšie transformačné metódy, sa v rámci našej práce zameriavame na jednoduchšie a výpočtovo menej náročné riešenia.

7.3.2 Metodika experimentu

Ako základ bol použitý referenčný model s hyperparametrami určenými pomocou nástroja Optuna, pričom vstupné snímky boli spracované vo farebnom priestore HSV. Na základe predchádzajúcich výsledkov bolo zároveň aplikované orezanie a maskovanie snímok, pri ktorom boli čierne pixely nahradené priemernou farebnou hodnotou obrázka.

Orezanie a maskovanie boli použité iba pri tých transformačných technikách, ktoré zachovávali kruhový tvar obrazu. V prípade metód, ktoré transformovali obraz na štvorcový výstup (napríklad rozdelením na rovnaké uhlové sektory), tieto kroky neboli potrebné, keďže výsledný obraz už pokrýval celú plochu snímky.

Tabuľka 14: Nastavenie modelu pre testovanie vplyvu úpravy geometrického skreslenia spôsobeného fisheye kamerou

Parameter	Hodnota
Počet vrstiev	4
Počet epoch	14
Normalizácia dávok	Vypnutá
Veľkosť jadra	5×5
Počet filtrov (1. vrstva)	32
Veľkosť vstupu	256×256
Rýchlosť učenia	0.0002035
Farebný priestor	HSV
Orezanie a maska	Áno (pri kruhových obrázkoch)

V rámci experimentu boli testované dva rôzne prístupy ku korekcii fisheye efektu:


- OpenCV lineárna projekcia
- rozdelenie obrazu na rovnaké uhlové sektory

Pre každú z týchto techník boli vykonané tri nezávislé behy, z ktorých boli vypočítané priemerné výsledky.

7.3.3 OpenCV lineárna projekcia

Cieľom lineárnej projekcie implementovanej v knižnici OpenCV je transformovať obraz so skreslením typu fisheye do podoby bližšej klasickému perspektívnemu zobrazeniu. Táto metóda využíva model kamery na potlačenie nelineárneho skreslenia, čím sa dosahuje rovnomernejšie rozloženie geometrických vzťahov v obraze.

V rámci implementácie boli použité funkcie OpenCV pre fisheye model. Keďže presné kalibračné parametre kamery neboli k dispozícii, vnútorné parametre aj koeficienty skreslenia boli aproximované na základe rozmerov vstupného obrazu. Následne bola vypočítaná upravená projekčná matica, ktorá umožňuje regulovať zachovanie zorného poľa, a vytvorené transformačné mapy definujúce prevod medzi vstupnými a výstupnými pixelmi. Samotná transformácia bola realizovaná pomocou premapovania, pričom výsledkom bol obraz s redukovaným skreslením. Na takto upravené snímky bola následne aplikovaná kruhová maska a orezanie z predchádzajúceho experimentu.




Obr. 27: Porovnanie originálneho vstupného obrázku (vľavo) s obrázkom po aplikovaní OpenCV lineárnej projekcie (vpravo)

7.3.4 Rozdelenie obrazu na rovnaké uhlové sektory

Druhou testovanou metódou bolo rozdelenie obrazu na rovnaké uhlové sektory, ktorého cieľom je transformovať kruhový obraz do reprezentácie, kde každý stĺpec zodpovedá rovnakému azimutálnemu uhlu. Tento prístup vychádza z prevodu obrazu z kartézskeho do polárneho súradnicového systému, čím sa zachováva uhlová informácia a eliminuje kruhový tvar vstupu.

Transformácia bola realizovaná pomocou funkcie *warpPolar* z knižnice OpenCV, pričom stred bol umiestnený do stredu snímky a maximálny polomer bol určený podľa jej rozmerov. Výsledný obraz má štvorcový tvar, kde horizontálna os reprezentuje azimutálny uhol a vertikálna os vzdialenosť od stredu (zenitu). Následne bol obraz otočený tak, aby zenit zodpovedal hornej časti snímky, čím sa zabezpečila konzistentná orientácia. Kruhová maska nebola aplikovaná, keďže výsledný obraz pokrýva celú plochu snímky.



Obr. 28: Porovnanie originálneho vstupného obrázku (vľavo) s obrázkom po aplikovaní rozdelenia obrazu na rovnaké uhlové sektory (vpravo)

7.3.5 Výsledky experimentu

Tabuľka 15: Priemerné výsledky analýzy vplyvu úpravy geometrického skreslenia spôsobeného fisheye kamerou

Metóda	Test RMSE (W/m ²)	Test MAE (W/m ²)	R ²
Bez korekcie	11.69	6.99	0.998
OpenCV lineárna projekcia	11.88	6.90	0.998
Uhlové sektory	125.61	71.37	0.787

Z dosiahnutých výsledkov vyplýva, že použitie OpenCV lineárnej projekcie nevedlo k jednoznačnému zlepšeniu výkonu modelu. Hoci v niektorých behoch došlo k miernemu zlepšeniu metrík, priemerne sa výsledky takmer nelíšili od referenčného prístupu bez korekcie. Naopak, metóda založená na rozdelení obrazu na rovnaké uhlové sektory viedla k výraznému zhoršeniu výkonu vo všetkých sledovaných metrikách, čo naznačuje, že takto transformovaná reprezentácia nie je vhodná pre použitý typ konvolučnej neurónovej siete.

7.3.6 Záver experimentu

Implementované metódy nedokázali priniesť konzistentné zlepšenie výkonu modelu, a preto sa v ďalších experimentoch od ich použitia upustilo.

Hoci komplexnejšie prístupy prezentované v práci [5] preukázali pozitívny vplyv pri ulohách súvisiacich s predikciou pohybu oblačnosti, predpokladá sa, že pri tejto úlohe zohráva dôležitejšiu úlohu farebná informácia obrazu, najmä jej reprezentácia vo farebnom priestore HSV, než presná geometrická konzistencia scény. Geometrické skreslenie preto

nepredstavuje zásadný problém pre daný typ predikcie a ďalšie rozširovanie tejto problematiky nebolo vzhľadom na dosiahnuté výsledky považované za efektívne.

8 Experimentálne testovanie augmentácií

8.1 Popis experimentu

Cieľom tejto experimentálnej časti bolo preskúmať vplyv rôznych techník augmentácie dát na presnosť modelu konvolučnej neurónovej siete pri predikcii solárneho žiarenia na základe obrazových a meteorologických vstupov. Experiment bol navrhnutý tak, aby systematicky vyhodnotil jednotlivé augmentačné metódy samostatne, čím sa minimalizoval vplyv ich vzájomných interakcií a umožnila sa objektívna analýza ich prínosu. Následne boli na základe získaných výsledkov vybrané najefektívnejšie augmentácie a kombinované do finálneho nastavenia s cieľom zlepšiť generalizačnú schopnosť modelu. Dôraz bol kladený najmä na stabilitu výsledkov naprieč viacerými behmi a na schopnosť modelu lepšie reagovať na variabilitu reálnych podmienok. Augmentácia ako koncept a jednotlivé augmentácie sú popísané v kapitole 3, resp. 3.2 – 3.5.

8.2 Vyradené augmentácie

Niektoré augmentačné techniky neboli do experimentov zahrnuté z dôvodu ich nevhodnosti pre daný typ dát alebo potenciálne negatívneho vplyvu na model.

- **Zrkadlenie** – vytvára fyzikálne nereálne situácie (napr. zmena polohy Slnka).
- **Shearing** – deformuje obraz spôsobom, ktorý sa v reálnych podmienkach nevyskytuje.
- **Úprava kontrastu** – podobný efekt bol už pokrytý technikou CLAHE.
- **CutMix** – kombinovanie viacerých obrazov narúša prirodzenú štruktúru oblohy.
- **Oklúzia** – odstraňuje dôležité časti obrazu, ktoré môžu obsahovať relevantné informácie pre predikciu.

8.3 Metodika experimentu

Pri realizácii experimentu boli použité najlepšie hyperparametre modelu získané v predchádzajúcich experimentoch.

Tabuľka 16: Nastavenie modelu pre testovanie vplyvu augmentácií

Parameter	Hodnota
Počet vrstiev	4
Počet epoch	14
Normalizácia dávok	Vypnutá
Veľkosť jadra	5×5
Počet filtrov (1. vrstva)	32
Veľkosť vstupu	256×256
Rýchlosť učenia	0.0002035
Farebný priestor	HSV
Orezanie a maska	Áno
Odstránenie fisheye efektu	Nie

Experimentálna metodológia bola navrhnutá tak, aby umožnila systematické a objektívne vyhodnotenie vplyvu jednotlivých augmentačných techník na výkonnosť modelu. Vstupné dáta boli rozdelené na tréningovú, validačnú a testovaciu množinu, pričom toto rozdelenie zostalo nemenné počas všetkých experimentov. Počas tréningu bol použitý generátor dát, ktorý načítaval obrazy po dávkach a aplikoval augmentáciu dynamicky. Pre každý obraz v tréningovej množine bolo s pravdepodobnosťou 15 % rozhodnuté, či bude augmentovaný, pričom v prípade výberu bola vždy aplikovaná práve jedna augmentačná technika.

Najskôr boli jednotlivé augmentácie testované samostatne, aby bolo možné presne určiť ich individuálny prínos. Každá augmentácia bola aplikovaná za rovnakých podmienok (15 % augmentovaných obrazov) a každý experiment bol zopakovaný šesťkrát s cieľom zohľadniť náhodnosť tréningového procesu. Na základe priemerných výsledkov boli následne vybrané najefektívnejšie augmentácie, ktoré boli kombinované do jedného finálneho nastavenia. V tomto prípade sa pre každý vybraný obraz (opäť s pravdepodobnosťou 15 %) náhodne zvolila konkrétna augmentácia na základe váh, ktoré boli určené podľa dosiahnutých výsledkov jednotlivých techník. Aj toto finálne nastavenie bolo testované v šiestich nezávislých behoch.


Testované augmentácie:

- **Rotácia** – náhodné otočenie obrazu v rozsahu približne -15° až $+15^\circ$.
- **Posun** – náhodný horizontálny a vertikálny posun maximálne do ± 10 % šírky a výšky obrazu.
- **Zmena mierky** – zmena mierky obrazu v rozsahu približne 0,9 až 1,1 pôvodnej veľkosti.


- **Úprava jasů** – násobenie hodnôt pixelov náhodným faktorom v intervale 0,7 až 1,3.
- **CLAHE** – zvýraznenie lokálneho kontrastu pomocou parametrov *clip limit* nastaveným na 2,0 a veľkosti mriežky 8×8 .
- **Pridanie šumu** – pridanie šumu s normálnym rozdelením (stredná hodnota 0, štandardná odchýlka 10).
- **Rozmazanie** – aplikácia Gaussovského filtra s veľkosťou jadra 15×15 .

Výkonnosť modelu bola vyhodnocovaná pomocou metrík RMSE, MAE a koeficientu determinácie R^2 na validačnej a testovacej množine, pričom dôraz bol kladený nielen na dosiahnuté hodnoty, ale aj na stabilitu výsledkov naprieč jednotlivými behmi.


8.4 Vizuálne ukážky augmentácií



Obr. 29: Príklady augmentácií: žiadna augmentácia (vľavo), rotácia (v strede), posun (vpravo)



Obr. 30: Príklady augmentácií: zmena mierky (vľavo), zmena jasů (v strede), CLAHE (vpravo)



Obr. 31: Príklady augmentácií: pridanie šumu (vľavo), rozmazanie (vpravo)

8.5 Výsledky experimentu

Výsledky jednotlivých experimentov boli vyhodnotené ako priemer hodnôt zo šiestich nezávislých behov modelu.

Tabuľka 17: Priemerné výsledky analýzy jednotlivých augmentácií a štatistika počtu aplikácií

Augmentácia	RMSE (W/m ²)	MAE (W/m ²)	R ²	Augmentované	Neaugmentované
Žiadna	12.91	7.41	0.998	-	-
Rotácia	14.10	8.50	0.997	~53800	~305600
Posun	15.71	9.85	0.996	~53950	~305400
Zmena mierky	18.31	11.62	0.995	~53840	~305580
Úprava jasu	16.07	9.89	0.997	~53910	~305460
CLAHE	13.30	8.00	0.998	~53890	~305550
Pridanie šumu	13.00	7.85	0.998	~53820	~304830
Rozmazanie	13.25	7.83	0.998	~53880	~305580

Najlepšie výsledky spomedzi jednotlivých augmentácií dosiahli techniky CLAHE, pridanie šumu a rozmazanie, ktoré sa najviac priblížili referenčnému modelu bez augmentácie. Naopak, geometrické transformácie, najmä posun a zmena mierky, viedli k zhoršeniu výkonu modelu, čo naznačuje ich nižšiu vhodnosť pre daný typ dát. Rotácia mala mierny negatívny vplyv, no stále bola použiteľná ako doplnková augmentácia.

Na základe predchádzajúcich výsledkov bola vytvorená kombinácia najlepších augmentácií, konkrétne rotácie, CLAHE, šumu a rozmazania, pričom každá augmentácia mala priradenú váhu určujúcu pravdepodobnosť jej výberu. Tento prístup umožnil zachovať diverzitu dát pri zachovaní dominantného vplyvu najefektívnejších techník.

Tabuľka 18: Priemerný počet použitých augmentácií pri tréovaní s kombináciou augmentácií

Augmentácia	Počet aplikácií
Rotácia	~7675
CLAHE	~20498
Pridanie šumu	~12845
Rozmazanie	~12821
Žiadna	~305256

Tabuľka 19: Priemerné výsledky kombinácií najvhodnejších augmentácií

Metrika	Hodnota
RMSE (W/m ²)	14.12
MAE (W/m ²)	8.45
R ²	0.997

8.6 Záver experimentu

Z výsledkov experimentov vyplýva, že ani jednotlivé augmentácie, ani ich kombinácie nevedli k výraznému zlepšeniu výkonu modelu. Z tohto dôvodu neboli dátové augmentácie zahrnuté do finálnej konfigurácie modelu.

9 Finálna evaluácia modelu

Finálne vyhodnotenie modelu bolo realizované s využitím všetkých optimalizovaných nastavení získaných v predchádzajúcich experimentoch. Na overenie generalizačnej schopnosti modelu bola použitá 10-násobná krížová validácia (popísaná v kapitole 6), ktorá umožňuje robustné posúdenie výkonu modelu na rôznych rozdeleniach dát.

Tabuľka 20: Nastavenie modelu pre finálnu evaluáciu

Parameter	Hodnota
Počet vrstiev	4
Počet epoch	14
Normalizácia dávok	Vypnutá
Veľkosť jadra	5×5
Počet filtrov (1. vrstva)	32
Veľkosť vstupu	256×256
Rýchlosť učenia	0.0002035
Farebný priestor	HSV
Orezanie a maska	Áno
Odstránenie fisheye efektu	Nie
Používané augmentácie	Žiadne


Okrem numerických metrík bola kvalita modelu analyzovaná aj vizuálne. Pre jeden z behov validácie bol sledovaný priebeh učenia prostredníctvom krivky učenia, čo umožnilo posúdiť stabilitu tréningu a identifikovať prípadné prejavy preučenia. Zároveň bol analyzovaný graf rezíduí, ktorý poskytol dodatočný pohľad na rozloženie chýb modelu a jeho schopnosť aproximovať cieľovú veličinu.

9.1 Výsledky finálnej evaluácie


Tabuľka 21: Výsledky 10-násobnej krížovej validácie finálneho modelu

Množina	MAE (W/m ²)	RMSE (W/m ²)
Trénovacia	6.1122 ± 0.1416	10.0449 ± 0.2484
Validačná	7.7802 ± 1.7930	12.5821 ± 3.1057
Testovacia	7.3295 ± 1.6081	12.0522 ± 2.6358

Výsledky finálneho modelu poukazujú na dobrú schopnosť generalizácie, keďže rozdiely medzi trénovacou, validačnou a testovacou množinou sú relatívne malé. Hodnoty MAE a RMSE mierne narastajú na validačných a testovacích dátach, čo je očakávané, avšak nedochádza k výraznému zhoršeniu výkonu, ktoré by naznačovalo preučenie modelu. Vyššia smerodajná odchýlka pri validačných a testovacích výsledkoch zároveň odráža variabilitu dát medzi jednotlivými behmi validácie. Celkovo možno konštatovať, že model dosahuje stabilný a konzistentný výkon naprieč rôznymi rozdeleniami dát.



Obr. 32: Krivka učenia finálneho modelu



Obr. 33: Graf rezíduí finálneho modelu

Na grafe priebehu učenia (Obr. č. 32) je možné pozorovať výrazný pokles chyby v počiatočných fázach tréningu, po ktorom nasleduje postupná stabilizácia oboch kriviek. Trénovacia aj validačná strata dosahujú podobné hodnoty bez výrazného odchýlenia, čo naznačuje dobrú generalizačnú schopnosť modelu a absenciu výrazného preučenia.

Graf rezíduí (Obr. č. 32) ukazuje, že rezidua sú rovnomerne rozložené okolo nulovej hodnoty, čo indikuje, že model nevykazuje systematickú chybu. Mierne väčší rozptyl pri vyšších hodnotách žiarenia naznačuje vyššiu variabilitu predikcie v tejto oblasti, čo je vzhľadom na vyššiu citlivosť systému pri vyšších hodnotách slnečného žiarenia očakávané, keďže aj malé zmeny v oblačnosti môžu viesť k výrazným zmenám intenzity žiarenia.

10 Diskusia výsledkov

10.1 Porovnanie finálneho a referenčného modelu

Tabuľka 22: Porovnanie finálneho a referenčného modelu

Metrika	Referenčný model	Finálny model
Test RMSE (W/m ²)	13.22	12.05 ± 2.64
Test MAE (W/m ²)	8.38	7.33 ± 1.61

Porovnaním referenčného a finálneho modelu možno konštatovať mierne zlepšenie výkonu, najmä z hľadiska metrík RMSE a MAE. Nižšie hodnoty týchto metrík priamo indikujú menšiu chybu predikcie, a teda presnejšie odhady slnečného žiarenia. Zníženie chybových hodnôt naznačuje, že aplikované úpravy vstupných dát mali pozitívny vplyv na presnosť modelu. Celkovo sa teda podarilo dosiahnuť lepšiu kvalitu modelu pri zachovaní jeho stability.

Napriek dosiahnutým výsledkom však stále existuje priestor na ďalšie zlepšenie modelu, napríklad využitím väčšieho množstva dát, komplexnejších architektúr neurónových sietí alebo výkonnejšieho hardvéru, ktorý by umožnil realizáciu rozsiahlejších experimentov a tréningovanie náročnejších modelov.

10.2 Vyhodnotenie metód predspracovania snímok

- **Zmena farebného priestoru na HSV** – výrazne odporúčaná, priniesla najväčšie zlepšenie výkonu.
- **Orezanie snímok** – odporúčané najmä pri výskyte čiernych oblastí bez informácie
- **Maskovanie** – odporúčané ako doplnok orezania, pomáha eliminovať nerelevantné časti obrazu
- **Augmentácie** – neodporúčané, nepreukázali zlepšenie výkonu modelu
- **Odstránenie fisheye skreslenia** – neodporúčané, neprinieslo zlepšenie a zvyšuje komplexnosť spracovania

Záver

Cieľom tejto práce bol návrh a implementácia modelu pre predikciu globálneho slnečného žiarenia na základe celooblohových snímok a následná analýza techník predspracovania vstupných dát a ich prínosu k úspešnosti modelu. Tento cieľ sa podarilo naplniť a identifikovať vhodnú konfiguráciu modelu, pričom navrhnuté riešenie dosahuje stabilné a presné výsledky.

V rámci práce bol implementovaný vlastný model konvolučnej neurónovej siete v programovacom jazyku Python a realizované rozsiahle experimenty zamerané na analýzu rôznych prístupov k spracovaniu obrazových dát. Súčasťou riešenia bolo testovanie vplyvu veľkosti vstupných obrázkov, farebných priestorov, jednotlivých farebných kanálov, orezania a maskovania snímok, dátových augmentácií a techník odstraňovania geometrického skreslenia spôsobeného fisheye kamerou. Významnou súčasťou práce bola aj optimalizácia hyperparametrov pomocou frameworku Optuna a následné finálne vyhodnotenie modelu prostredníctvom 10-násobnej krížovej validácie.

Experimenty ukázali, že nie všetky techniky predspracovania vedú k zlepšeniu výsledkov. Najväčší prínos mala vhodná voľba farebného priestoru, konkrétne HSV, spolu s jednoduchými úpravami, ako sú orezanie a maskovanie snímok. Na druhej strane techniky, ako dátové augmentácie alebo odstraňovanie fisheye skreslenia, nepriniesli očakávané zlepšenie, čo poukazuje na špecifiká riešenej úlohy a charakter analyzovaných dát.

Výsledný model preukázal dobrú schopnosť generalizácie a predstavuje efektívne riešenie pre predikciu slnečného žiarenia z obrazových dát. Práca zároveň ukázala, že pri tejto úlohe zohráva kľúčovú úlohu najmä farebná informácia obrazu, zatiaľ čo geometrická presnosť snímok má menší význam. Získané poznatky môžu slúžiť ako základ pre ďalší výskum v oblasti predikcie slnečného žiarenia pomocou metód počítačového videnia a hlbokého učenia.

Literatúra

- [1] LORENZ, E., HURKA, J., BEYER, H. G., HEINEMANN, D. *Irradiance Forecasting for the Power Prediction of Grid-Connected Photovoltaic Systems*. In: *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* [online]. 2009, April, s. 1 [cit. 2026-27-04]. Dostupné na: <https://doi.org/10.1109/JSTARS.2009.2020300>
- [2] COGLIANI, E. *The Role of the Direct Normal Irradiance (DNI) Forecasting in the Operation of Solar Concentrating Plants*. In: *Energy Procedia* [online]. 2014, č. 49 [cit. 2026-27-04]. Dostupné na: <https://doi.org/10.1016/j.egypro.2014.03.170>
- [3] SUDHARSHAN, KON DURU a kol. *Systematic Review on Impact of Different Irradiance Forecasting Techniques for Solar Energy Prediction*. In: *Energies* [online]. 2022, č. 15, s. 1 [cit. 2026-27-04]. Dostupné na: <https://www.mdpi.com/1996-1073/15/17/6267>
- [4] WANG, K., DICKINSON, R. E., MA, Q., AUGUSTINE, J. A., WILD, M. *Measurement Methods Affect the Observed Global Dimming and Brightening* [online]. 2013 [cit. 2026-27-04]. Dostupné na: <https://doi.org/10.1175/JCLI-D-12-00482.1>
- [5] JULIAN, L., SANKARANARAYANAN, A. C. *Precise Forecasting of Sky Images Using Spatial Warping* [online]. 2024, September [cit. 2026-27-04]. Dostupné na: <https://doi.org/10.48550/arXiv.2409.12162>
- [6] HENSEL, S., MARINOV, M. B., SCHWARZ, R. *Fisheye Camera Calibration and Distortion Correction for Ground Based Sky Imagery*. In: *IEEE XXVII International Scientific Conference Electronics* [online]. Sozopol, Bulgaria, 2018, [cit. 2026-27-04]. Dostupné na: 10.1109/ET.2018.8549649
- [7] GOODFELLOW IAN; BENGIO, Yoshua; COURVILLE, Aaron. *Deep Learning*. Cambridge: Massachusetts Institute of Technology, 2016. 775 s. ISBN 978-0-262-03561-3.
- [8] MURATBEKOVA, M. a kol. *Color models in image processing: a review and experimental comparison*. In: *Discover Applied Science* [online]. 2026, č. 8 [cit. 2026-27-04]. Dostupné na: <https://doi.org/10.1007/s42452-025-08192-7>

- [9] SWAMPYANK. *YCbCr-sample.png* [obrázok online]. 2005 [cit. 2026-27-04]. Dostupné na: <https://en.wikipedia.org/wiki/YCbCr>
- [10] ALBERT, S. a kol. *Comparison of Image Normalization Methods for Multi-Site Deep Learning*. In: *Discover Applied Science* [online]. 2023, č. 13 [cit. 2026-27-04]. Dostupné na: <https://doi.org/10.3390/app13158923>
- [11] KHALIFA, N. E., LOEY, M., MIRJALILI, S. *A comprehensive survey of recent trends in deep learning for digital images augmentation..* In: *Artif Intel* [online]. 2022, č. 55 [cit. 2026-27-04]. Dostupné na: <https://doi.org/10.1007/s10462-021-10066-4>
- [12] *Mountains-clahe.png* [obrázok online]. [cit. 2026-27-04]. Dostupné na: <https://imagemagick.org/clahe/#gsc.tab=0>
- [13] NDIRITU, E. *Noise in Image Processing and How to Add It to Images in Python* [online]. 2024 [cit. 2026-27-04]. Dostupné na: <https://medium.com/@muyandiritujr/noise-in-image-processing-and-how-to-add-it-to-images-in-python-456a434dcc3f>
- [14] KHANDELWAL, S. *CutMix: A new strategy for Data Augmentation* [online]. 2020 [cit. 2026-27-04]. Dostupné na: <https://sarthakforwet.medium.com/cutmix-a-new-strategy-for-data-augmentation-bbc1c3d29aab>
- [15] SUDHARSHAN, KONDURU a kol. *Systematic Review on Impact of Different Irradiance Forecasting Techniques for Solar Energy Prediction*. In: *Energies* [online]. 2022, č. 15, s. 11-12 [cit. 2026-27-04]. Dostupné na: <https://www.mdpi.com/1996-1073/15/17/6267>
- [16] SUDHARSHAN, KONDURU a kol. *Systematic Review on Impact of Different Irradiance Forecasting Techniques for Solar Energy Prediction*. In: *Energies* [online]. 2022, č. 15, s. 13 [cit. 2026-27-04]. Dostupné na: <https://www.mdpi.com/1996-1073/15/17/6267>
- [17] O' MAHONY, N. a kol. *Deep Learning vs. Traditional Computer Vision* [online]. Institute of Technology, s. 1 [cit. 2026-27-04]. Dostupné na: https://www.researchgate.net/publication/331586553_Deep_Learning_vs_Traditional_Computer_Vision

- [18] O' MAHONY, N. a kol. *Deep Learning vs. Traditional Computer Vision* [online]. Institute of Technology, s. 5-6 [cit. 2026-27-04]. Dostupné na: https://www.researchgate.net/publication/331586553_Deep_Learning_vs_Traditional_Computer_Vision
- [19] O' MAHONY, N. a kol. *Deep Learning vs. Traditional Computer Vision* [online]. Institute of Technology, s. 3 [cit. 2026-27-04]. Dostupné na: https://www.researchgate.net/publication/331586553_Deep_Learning_vs_Traditional_Computer_Vision
- [20] O' MAHONY, N. a kol. *Deep Learning vs. Traditional Computer Vision* [online]. Institute of Technology, s. 6-8 [cit. 2026-27-04]. Dostupné na: https://www.researchgate.net/publication/331586553_Deep_Learning_vs_Traditional_Computer_Vision
- [21] GREAT LEARNING EDITORIAL TEAM. *Introduction to Convolutional Neural Network (CNN)* [online]. 2025 [cit. 2026-27-04]. Dostupné na: <https://www.mygreatlearning.com/blog/cnn-model-architectures-and-applications/>
- [22] ZAHEER, R., SHAZIYA, H. *A Study of the. Optimization Algorithms in Deep Learning..* In: *Third International Conference on Inventive Systems and Control (ICISC)* [online]. Coimbatore, India, 2019, s. 536-539 [cit. 2026-27-04]. Dostupné na: 10.1109/ICISC44355.2019.9036442
- [23] CHICCO, D., WARRENS, M. J., JURMAN, G. *The coefficient of determination R-squared is more informative than SMAPE, MAE,MAPE, MSE and RMSE in regression analysis evaluation* [online]. 2021[cit. 2026-27-04]. Dostupné na: https://www.researchgate.net/publication/353007143_The_coefficient_of_determination_R-squared_is_more_informative_than_SMAPE_MAE_MAPE_MSE_and_RMSE_in_regression_analysis_evaluation
- [24] ABEDIN, T., XU, H., UDDIN, S. *The impact of K selection in K-fold cross-validation on bias and variance in supervised learning models.* In: *Sci Rep* [online]. 2026, č. 16 [cit. 2026-27-04]. Dostupné na: <https://doi.org/10.1038/s41598-026-37247-x>

- [25] TEKUYA AKIBA, SHOTARO SANO, TOSHIHIKO YANASE, TAKERU OHTA, MASANORI KOYAMA. *Optuna: A Next-generation Hyperparameter Optimization Framework*. In: *KKD* [online]. 2019 [cit. 2026-27-04]. Dostupné na: <https://optuna.org/>
- [26] NIE, Y., PALETTA, Q., SCOTT A., POMARES L. M., ARBOD, G., SGOURIDIS, S., LASENBY, J., BRANDT, A. *Sky image-based solar forecasting using deep learning with heterogeneous multi-location data: Dataset fusion versus transfer learning*. In: *Applied Energy* [online]. 2024, č. 369 [cit. 2026-27-04]. Dostupné na: <https://doi.org/10.1016/j.apenergy.2024.123467>
- [27] AL-LAHHAM, A., THEEB, O., ELALEM, K., ALSHAWI, T. A., ALSHEBEILI, S. A. *Sky Imager-Based Forecast of Solar Irradiance Using Machine Learning* In: *Electronics* [online]. 2020 [cit. 2026-27-04]. Dostupné na: <https://www.mdpi.com/2079-9292/9/10/1700>
- [28] ŠEBEŇA, Marián a KACŮR, Juraj. Prediction of Solar Energy from Sky Images and Meteorological Data Using Neural Networks. In: Mario, MUŠTRA; Josip, VUKOVIĆ a Jelena, BOŽEK. *Proceedings ELMAR-2023*. Zadar: Croatian Society Electronics in Marine, 2023, s. 189–192. ISBN 979-8-3503-2511-9.
- [29] NTAVELIS, E., REMUND, J., SCHMID, P. *SkyCam: A Dataset of Sky Images and their Irradiance values* [online]. 2021 [cit. 2026-27-04]. Dostupné na: <https://github.com/entavelis/SkyCam>

Použitie nástrojov umelej inteligencie

OpenAI (2026), ChatGPT 5.3, Časť 1, 2, 3, 4: pomoc pri preklade odborných textov

OpenAI (2026), ChatGPT 5.3, Časť 5, 6, 7, 8, 9, 10, Záver: preformulovanie vybraných častí textu autora

OpenAI (2026), ChatGPT 5.3, Časť 6, 7, 8, 9, 10: generovanie tabuliek pri experimentoch

OpenAI (2026), ChatGPT 5.3: asistencia pri tvorbe a ladení zdrojového kódu

OpenAI (2026), ChatGPT 5.3: vygenerovanie dokumentácie zdrojového kódu

Dodatok A: Pokyny na spustenie a používanie zdrojového kódu

Zdrojový kód spolu s jeho dokumentáciou je súčasťou elektronickej prílohy, ako aj verejného repozitára autora: <https://github.com/RobertSumsala/MastersThesis>

Kód je navrhnutý tak, aby jeho spustenie prebiehalo prostredníctvom hlavného súboru `ConnorMain.py`. V tomto súbore je definovaná funkcia `main()`, ktorá slúži ako vstupný bod programu a obsahuje jednotlivé funkcie reprezentujúce realizované experimenty.

Všetky experimentálne funkcie sú v predvolenom stave zakomentované, pričom odkomentovaná je funkcia zabezpečujúca tréning finálneho modelu s optimálnymi nastaveniami a následné vykonanie 10-násobnej krížovej validácie. Používateľ má možnosť odkomentovať ľubovoľné funkcie podľa potreby a spúšťať jednotlivé experimenty samostatne alebo v kombinácii.

Súčasťou elektronickej prílohy, ako aj vyššie uvedeného repozitára, je textový súbor obsahujúci konfiguráciu modelu, ktorý je využívaný pri spúšťaní viacerých experimentov, vrátane finálnej funkcie pre 10-násobnú krížovú validáciu. Tento súbor obsahuje optimálne hodnoty hyperparametrov získané na základe realizovaných experimentov. Hodnoty je možné v prípade potreby upraviť, avšak predvolená konfigurácia reprezentuje najlepšie dosiahnuté nastavenie modelu.


Podrobnejší popis funkcionality jednotlivých častí kódu je uvedený priamo v zdrojovom kóde.

Prílohy

Príloha 1: Schéma finálneho modelu	86
Príloha 2: Obsah elektronickej prílohy	87

Príloha 1: Schéma finálneho modelu

- Schéma reprezentujúca architektúru finálneho modelu. Schéma v plnom rozlíšení a lepšej kvalite je súčasťou elektronickej prílohy



Optimalizácia: Adam
Rýchlosť učenia: 0.0002035
Stratová funkcia: MSE
Vyhodnocovacia metrika: MAE

Príloha 2: Obsah elektronickej prílohy

- Zdrojový kód projektu
- Textový súbor obsahujúci najlepšiu konfiguráciu modelu vo formáte požadovanom zdrojovým kódom
- Dokumentácia k finálnej implementácii
- Schéma finálneho modelu v plnom rozlíšení (originálna verzia)
- Digitálna verzia diplomovej práce (PDF)

Všetky uvedené materiály sú zároveň dostupné aj na verejnom repozitári autora:
<https://github.com/RobertSumsala/MastersThesis>